

ЛЕКЦИЯ 2

ТОЧЕЧНОЕ ОЦЕНИВАНИЕ И ЕГО СВОЙСТВА

Начнем с общей постановки задачи оценивания

Определение. Пусть $X = (X_1, \dots, X_n)$ выборка объема n из семейства распределений $\mathcal{F}_\theta$, $\theta \in \Theta$. *Статистикой (оценкой)* параметра θ называется произвольная функция $\theta^* = \theta^*(X_1, \dots, X_n)$, являющаяся случайной величиной

Замечание. Отметим, что статистика зависит только от выборки, а параметр θ на нее не влияет и в нее не заложен, хотя и служит для оценивания этого самого параметра

Очевидно, что если мы говорим о необходимости оценить параметр θ , то результат такого оценивания должен быть в некотором смысле близок к оцениваемому параметру, иначе смысла в таком оценивании немного. Поэтому надо договориться, что мы будем понимать под этим «близок»

Определение. Статистика $\theta^* = \theta^*(X_1, \dots, X_n)$ называется *несмещенной* оценкой параметра θ , если справедливо равенство $E\theta^* = \theta$

Это означает, что «в среднем» наша оценка равна оцениваемому параметру

Несмещенность хорошее свойство, но в природе встречается редко. Чаще удается обеспечить лишь ослабленное свойство асимптотическую несмещенность

Определение. Статистика $\theta^* = \theta^*(X_1, \dots, X_n)$ называется *асимптотически несмещенной* оценкой параметра θ , если выполняется $E\theta^* \xrightarrow{n \rightarrow \infty} \theta$

Асимптотическая несмещенность это несмещенность в пределе, при неограниченном возрастании выборки. Конечно, несмещенность влечет за собой асимптотическую несмещенность. Обратное, вообще говоря, неверно

Естественным выглядит и следующее требование к «хорошей» оценке

Определение. Статистика $\theta^* = \theta^*(X_1, \dots, X_n)$ называется *состоятельной* оценкой параметра θ , если выполняется $\theta^* \xrightarrow[n \rightarrow \infty]{P} \theta$

Это означает, что последовательность оценок (зависящая от объема выборки) приближается к неизвестному параметру

Пример

Вернемся, к примеру прошлой лекции об оценивании вероятности

$$p^* = \frac{S_n}{n}$$

$$E\left(\frac{S_n}{n}\right) = \frac{1}{n} E S_n = \frac{np}{n} = p \text{ и } \frac{S_n}{n} \xrightarrow[n \rightarrow \infty]{P} p$$

Выполненные выкладки говорят о том, что предложенная оценка вероятности является несмещенной и состоятельной

ОЦЕНИВАНИЕ ВЫБОРОЧНЫХ МОМЕНТОВ

Ранее уже говорилось, что поскольку эмпирическая ФР строится также как ФР дискретной СВ, принимающей значения $X_1, \dots, X_n$ с равными

вероятностями $\frac{1}{n}$, то возможно и выборочные моменты можно рассчитывать по формулам для дискретной СВ

Определение. *Выборочным средним $\bar{X}$ (выборочным математическим ожиданием $\bar{m}$)* называется СВ

$$\bar{X} = \frac{X_1 + \dots + X_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i$$

Выборочное среднее логично считать оценкой математического ожидания. Покажем, насколько это так


Будем полагать, что все элементы выборки $X = (X_1, \dots, X_n)$ извлечены из одной генеральной совокупности ξ , и что $E X_i = E \xi = \mu$, $D X_i = D \xi = \sigma^2$ и они конечны

Пример

Рассмотрим рост 5 студентов: $X = (168, 172, 175, 180, 185)$

Оценка среднего роста $\bar{X} = \frac{168+172+175+180+185}{5} = 176$

Иллюстрация 1



Теорема. (свойства среднего) Выборочное среднее обладает следующими свойствами:

- (1) $E\bar{X} = \mu$, т. е. является несмещенной оценкой МО
- (2) $\bar{X} \xrightarrow[n \rightarrow \infty]{P} \mu$, т. е. является состоятельной оценкой МО
- (3) $Y_n = \sqrt{n} \frac{\bar{X} - \mu}{\sigma} \xrightarrow[n \rightarrow \infty]{d} Y \sim N_{0,1}$, т. е. является асимптотически нормальной оценкой МО

Доказательство:

$$(1) E\bar{X} = E\left(\frac{X_1 + \dots + X_n}{n}\right) = \frac{1}{n} E \sum_{i=1}^n X_i = \frac{1}{n} \sum_{i=1}^n E X_i = \frac{n\mu}{n} = \mu$$

(2) Следует из ЗБЧ Чебышёва

(3) Следует из ЦПТ

Определение. Выборочным моментом k -го порядка называется СВ

$$\bar{X}^k = \frac{X_1^k + \dots + X_n^k}{n} = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Для выборочных моментов k -го порядка формулируется и доказывается аналогичная теорема о свойствах

Перейдем к рассмотрению центрального момента 2-го порядка – дисперсии

Определение. Выборочной дисперсией называется СВ

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Пример

Для примера с ростом студентов посчитаем выборочную дисперсию

$$S^2 = \frac{178}{5} = 35,6 \Rightarrow S = 5,97$$

Иллюстрация 2





Иллюстрация 3

Построим интервал $[\bar{X} - S; \bar{X} + S]$ показывающий «типичный» разброс данных вокруг среднего



Для нормального распределения 68% наблюдений попадает в интервал $[\bar{X} - S; \bar{X} + S]$

В нашем случае 60%, но ведь и объем выборки небольшой

Убедимся, что и для выборочной величины справедлива формула известная нам из ТВ

Теорема. Для выборочной дисперсии справедливо соотношение

$$S^2 = \overline{X^2} - \bar{X}^2$$

Доказательство:

$$\begin{aligned} S^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) = \\ &= \frac{1}{n} \sum_{i=1}^n X_i^2 - 2\bar{X} \frac{1}{n} \sum_{i=1}^n X_i + \bar{X}^2 = \overline{X^2} - 2\bar{X}^2 + \bar{X}^2 = \overline{X^2} - \bar{X}^2 \end{aligned}$$

Сформулируем в виде теоремы свойства выборочной дисперсии, имея в виду сказанное ранее, что $D X_i = \sigma^2$ и конечна

Теорема. Выборочная дисперсия обладает следующими свойствами:

- (1) S^2 смещенная оценка дисперсии, а именно $E S^2 = \frac{n-1}{n} \sigma^2$
- (2) $S^2 \xrightarrow[n \rightarrow \infty]{P} \sigma^2$, т. е. является состоятельной оценкой дисперсии

Доказательство:

Остановимся на доказательстве только первого утверждения

$$E S^2 = E \overline{X^2} - E \bar{X}^2 = E \left(\frac{X_1^2 + \dots + X_n^2}{n} \right) - E \left(\frac{X_1 + \dots + X_n}{n} \right)^2$$

$$\text{Первое слагаемое } E \left(\frac{X_1^2 + \dots + X_n^2}{n} \right) = \frac{1}{n} E (X_1^2 + \dots + X_n^2) = E X_1^2$$

$$\begin{aligned} \text{Второе слагаемое } E \left(\frac{X_1 + \dots + X_n}{n} \right)^2 &= E \sum_{i=1}^n \frac{X_i^2}{n^2} + 2E \sum_{i < j} \frac{X_i X_j}{n^2} = \\ &= \frac{1}{n^2} \left(E \sum_{i=1}^n X_i^2 + 2E \sum_{i < j} X_i X_j \right) \underset{\text{из независ.}}{=} \frac{E X_1^2}{n} + \frac{2}{n^2} \sum_{i < j} (E X_1)^2 = \end{aligned}$$

В сумме $\frac{n(n-1)}{2}$ слагаемых. Поэтому

$$E \left(\frac{X_1 + \dots + X_n}{n} \right)^2 = \frac{1}{n} E X_1^2 + \frac{n-1}{n} (E X_1)^2$$

Тогда

$$E S^2 = E X_1^2 - \frac{1}{n} E X_1^2 - \frac{n-1}{n} (E X_1)^2 = \frac{n-1}{n} (E X_1^2 - (E X_1)^2) = \frac{n-1}{n} D X_1$$

Определение. Несмещенной выборочной дисперсией называется СВ

$$\overline{\sigma^2} = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$


Замечание. Естественно, что заметной такая корректировка будет только для небольших выборок

Пример

Для роста студентов $\overline{\sigma^2} = \frac{178}{4} = 44,5 \Rightarrow S = 6,67$. Отклонение $\overline{\sigma^2}$ и S^2

существенное

Иллюстрация 4



ДРУГИЕ ХАРАКТЕРИСТИКИ ВЫБОРКИ

Определение. Пусть выборка $X = (X_1, \dots, X_n)$ извлечена из генеральной совокупности ξ . Выборочной модой $\bar{m}_0$ для выборки $X = (X_1, \dots, X_n)$ называется чаще всего наблюдаемое значение, т. е.

$$n_i(\bar{m}_0) = \max_i n_i$$

В случае дискретных СВ оценка моды – это конкретное значение из выборки с максимальной частотой появления

При рассмотрении непрерывных данных, когда строится гистограмма распределения можно указать лишь модальный интервал – интервал с максимальной частотой попаданий (с самым высоким столбцом), а не точное значение моды


Отметим, что

- Ширина интервала в гистограммы может сместить «самый высокий столбец»
- Выборка может иметь несколько мод

Пример

Рассматриваем тот же пример с ростом студентов (некоторые значения немного изменены для наглядности). Модальные интервалы меняются в зависимости от выбора длины интервала гистограммы

Иллюстрация 5



Пример

- (1) $X = (2, 3, 3, 4, 5, 3, 3)$ – унимодальная выборка
- (2) $X = (1, 1, 2, 3, 4, 4, 1, 4)$ – бимодальная выборка
- (3) $X = (168, 172, 175, 180, 185)$ – мода отсутствует, каждое значение уникально

Иллюстрация 6



Определение. Пусть выборка $X = (X_1, \dots, X_n)$ извлечена из генеральной совокупности ξ . Выборочной медианой $\bar{m}_e$ для выборки $X = (X_1, \dots, X_n)$ называют число

$$\bar{m}_e = \begin{cases} X_{\frac{n+1}{2}}, n - \text{нечетное} \\ \frac{X_{\frac{n}{2}} + X_{\frac{n+1}{2}}}{2}, n - \text{четное} \end{cases}$$

Отметим, что


- медиана интуитивно понятна как «середина» данных
- существует для любых данных
- в отличие от среднего «не реагирует» на выбросы данных

Пример

При нечетном $n = 7$, $X = (168, 172, 175, 180, 185, 162, 178)$ выбираем среднее значение $\bar{m}_e = 175$

При четном $n = 6$, $X = (165, 170, 172, 175, 180, 188)$ находим полусумму двух средних $\bar{m}_e = \frac{172 + 175}{2} = 173,5$

Иллюстрация 7




Пример

Сравним выборочное среднее и медиану при различных исходных данных (рост студентов)

- (1) обычные данные $X = (168, 172, 175, 180, 185)$, $\bar{X} = 176$, $\bar{m}_e = 175$
- (2) данные с выбросом $X = (168, 172, 175, 180, 250)$, $\bar{X} = 189$, $\bar{m}_e = 175$

Иллюстрация 8



Определение. Пусть выборка $X = (X_1, \dots, X_n)$ извлечена из генеральной совокупности ξ . Выборочной квантилью уровня $\alpha \in (0, 1)$ для выборки $X = (X_1, \dots, X_n)$ называют число

$$\bar{x}_\alpha = \begin{cases} X_{[n\alpha]+1}, & n\alpha \notin \mathbb{Z} \\ \frac{X_{n\alpha} + X_{n\alpha+1}}{2}, & n\alpha \in \mathbb{Z} \end{cases}$$

Замечание. Квантиль уровня $\alpha = 0,5$ является медианой

Квантиль – это «рубеж», который делит упорядоченные выборочные данные на части по количеству наблюдений, а не по их значениям
Квантили отвечают на вопрос:

«Какое значение отделяет нижние $p\%$ данных от верхних $(100-p)\%$?»

Квантили важны, потому что

- выбросы искажают выборочное среднее, а квантили не зависят от экстремальных значений
- 5%- и 95% квантили показывают границы типичных значений

Квантили превращают сложное распределение в простые ориентиры:

- Где начинается «низкий» рост?
- Где заканчивается «средний» доход?
- Какова граница «крайне высоких» значений?

Это делает их незаменимыми для анализа данных в медицине, экономике, образовании

Пример

Рост студентов (выборка увеличена для большей наглядности)

$X = (162, 165, 168, 170, 172, 174, 176, 178, 180, 183, 186, 190)$

Квантиль 10% – какой рост у самого низкого десятка процентов? – 10% студентов имеют рост ниже 166 см

Квантиль 50% (медиана) – кто находится ровно посередине? – половина студентов ниже, а выше 175 см

Квантиль 90% – начиная с какого роста идут самые высокие 10%? – 10% студентов выше 185 см

Каждый квантиль — это «место в этой очереди», а не конкретный сантиметр

Иллюстрация 9

