ЛЕКЦИЯ 3

ОЦЕНКА МОМЕНТОВ ПО ГРУППИРОВАННОЙ ВЫБОРКЕ

Мы продолжаем говорить об оценивании моментов выборки. Как указывалось ранее, при большом объеме выборки в предположении, что генеральная совокупность имеет непрерывное распределение мы представляли выборочный закон распределения в виде группированной выборки и строили гистограмму.

Возникает естественный вопрос, как надо изменить формулы для оценки основных моментов в этом случае и как это изменение повлияет на качество оценивания?

Представляется естественным использовать следующие формулы

Определение. Пусть $[X_0;X_n]$ диапазон возможных значений выборки разбит на m промежутков $[X_0;X_1),[X_1;X_2),\ldots,[X_{m-1};X_m]$, причем в каждый из них попало $n_1,n_2,\ldots,n_m$ элементов выборки. Тогда оценки выборочных моментов будем вычислять по формулам

$\overline{X}_g=\frac{1}{n}\sum_{k=1}^{m}n_k\hat{X}_k$, $\overline{\sigma}_g^2=\frac{1}{n-1}\sum_{k=1}^{m}n_k\left(\hat{X}_k-\overline{X}\right)^2$, где $\hat{X}_k$ – середина интервала $[X_{k-1};X_k]$

Замечание. Предложенные формулы фактически «считают», что все элементы выборки, попавшие в один промежуток, равны между собой и равны середине интервала

Возникают естественные вопросы, насколько это изменяет значение оценки, что и в какой мере влияет на величину изменений?

Сравним значения выборочного среднего и $\overline{X}_g$, полученные для разных интервалов гистограмм

<u>Иллюстрация 1</u>

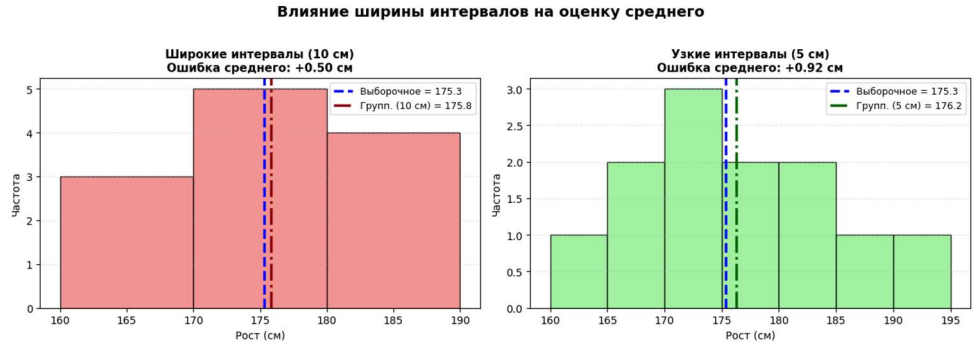

Выборочное среднее: 175.33 см | Выборочная дисперсия: 72.42 см²

Группировка 10 см → среднее: 175.83 (ошибка +0.50), дисперсия: 62.88 (ошибка -9.55)

Группировка 5 см → среднее: 176.25 (ошибка +0.92), дисперсия: 77.84 (ошибка +5.42)

Т. о. видим, что значения средних отличаются, и на отличия влияют длины интервалов

Оценим эти отличия. Посмотрим, что происходит при группировке со средним и дисперсией

(1) Пусть интервал $[x_{k-1};x_k)$ имеет длину $h_k=x_k-x_{k-1}$, середину $\hat{x}_k=\frac{x_k+x_{k-1}}{2}$ и содержит n_k элементов выборки

Тогда имеем $\overline{x}_g=\frac{1}{n}\sum_{k=1}^{m}n_k\hat{x}_k$ и

$\overline{x}=\frac{1}{n}\sum_{k=1}^{m}\sum_{i\in I_k}x_i$, где I_k – набор индексов в k-м интервале. Здесь мы сначала суммируем элементы в интервалах, а потом складываем эти суммы

Погрешность для среднего $\Delta_{\overline{x}}=\overline{x}_g-\overline{x}=\frac{1}{n}\sum_{k=1}^{m}\underbrace{\sum_{i\in I_k}\left(\hat{x}_k-x_i\right)}_{\Delta_k}=\frac{1}{n}\sum_{k=1}^{m}\Delta_k$.

Здесь Δ_k – суммарная ошибка замены всех x_i в k-м интервале

Оценим погрешность Δ_k

(2) <u>Оценка погрешности в одном интервале</u>

Отклонение некоторого значения из интервала от его середины равно $\varepsilon_i = x_i - \hat{x}_k$. Очевидно, что $|\varepsilon_i| \le \frac{h_k}{2}$. Тогда суммарная погрешность по всему интервалу $\Delta_k = \sum_{i \in I^*} \varepsilon_i$

В случае симметричности распределения относительно $\hat{x}_k$ $\Delta_k \to 0$.

В противном случае наблюдается завышение $\Delta_k > 0$ или занижение $\Delta_k < 0$ оценки

(3) <u>Оценка погрешности в случае равномерного распределения внутри каждого интервала</u>

Предположим, что внутри каждого интервала наблюдения распределены равномерно. Тогда $\mathrm{E}\Delta_k = 0 \Rightarrow \mathrm{E}\Delta_{\bar{x}} = \mathrm{E}\left(\frac{1}{n}\sum_{k=1}^{m}\Delta_k\right) = 0$, т. е. в среднем ошибки нет, оценка несмещенная

При этом дисперсия равномерного распределения $\mathrm{D}\Delta_k = \frac{h_k^2}{12}$ и

$$\mathrm{D}\Delta_{\bar{x}} = D\left(\frac{1}{n}\sum_{k=1}^{m}\Delta_k\right) = \frac{1}{n^2}\sum_{k=1}^{m} n_k \frac{h_k^2}{12} = \frac{1}{12n}\sum_{k=1}^{m}\frac{n_k}{n}h_k^2$$

Если использовать разбиение на равные интервалы $h_k = h$, то получим дисперсию $\mathrm{D}\Delta_{\bar{x}} = \frac{h^2}{12n} \Rightarrow \sigma_{\Delta_{\bar{x}}} = \frac{h}{\sqrt{12n}}$

<u>Вывод</u>: разброс растет линейно с шириной интервала и убывает пропорционально $\sqrt{n}$

(4) <u>Оценка погрешности для выборочной дисперсии при равномерном распределении внутри каждого интервала</u>

Для каждого x_i в k-м интервале запишем

$$x_i - \bar{x} = \underbrace{x_i - \hat{x}_k}_{\text{отклонение внутри интервала}} + \underbrace{\hat{x}_k - \bar{x}}_{\text{отклонение середины от среднего}}$$

После возведения в квадрат просуммируем. При этом в правой части удвоенное произведение равно 0, т. к. при симметричном распределении суммарное отклонение x_i от середины равно 0

$$\sum_{i=1}^{n}(x_i - \bar{x})^2 = \underbrace{\sum_{k=1}^{m}\sum_{i \in I_k}(x_i - \hat{x}_k)^2}_{\text{внутриинтервальная}} + \underbrace{\sum_{k=1}^{m} n_k(\hat{x}_k - \bar{x})^2}_{\text{межинтервальная}}.$$ Тогда

$$\bar{\sigma}^2 = \underbrace{\frac{1}{n-1}\sum_{k=1}^{m}\sum_{i \in I_k}(x_i - \hat{x}_k)^2}_{\text{внутриинтервальная дисперсия}} + \frac{1}{n-1}\underbrace{\sum_{k=1}^{m} n_k(\hat{x}_k - \bar{x})^2}_{\text{межинтервальная дисперсия}}$$ или

$$\bar{\sigma}^2 - \frac{1}{n-1}\sum_{k=1}^{m}\sum_{i \in I_k}(x_i - \hat{x}_k)^2 = \bar{\sigma}_g^2$$

С учетом $\mathrm{E}\left(\sum_{i \in I_k}(x_i - \hat{x}_k)^2\right) = n_k \cdot \frac{h_k^2}{12}$, делаем <u>вывод</u>:

$\bar{\sigma}_g^2$ *занижает* выборочную дисперсию на величину $\sim \frac{1}{n}\sum_{k=1}^{m} n_k \cdot \frac{h_k^2}{12}$, а при одинаковом шаге $\sim \frac{h^2}{12}$

Оптимальность оценок

Вернемся к разговору о качестве оценивания. Опишем общий подход

Определение. Оценку $\theta^* \in \Theta$ называют *оптимальной*, если она минимизирует заданный критерий качества

Замечание. Оптимальность всегда относительна, определяется выбранным критерием качества

Приведем пример одного из подходов к понятию оптимальности, взяв в качестве критерия $\mathrm{MSE}(\theta^*)$ (один из распространенных)

Определение. Будем называть *среднеквадратической ошибкой оценки параметра* θ^* величину $\mathrm{MSE}(\theta^*) = \mathrm{E}\left((\theta^* - \theta)^2\right)$

Другими словами, можно сказать, что это среднее значение квадрата ошибки оценки

Заметим следующее

Перепишем формулу в виде

$$\mathrm{MSE}\left(\theta^*\right)=\mathrm{E}\left(\left(\theta^*-\theta\right)^2\right)=\mathrm{E}\left(\left(\left(\theta^*-\mathrm{E}\,\theta^*\right)+\left(\mathrm{E}\,\theta^*-\theta\right)\right)^2\right)=$$

$$=\mathrm{E}\left(\theta^*-\mathrm{E}\,\theta^*\right)^2+2\left(\mathrm{E}\,\theta^*-\theta\right)\underbrace{\mathrm{E}\left(\theta^*-\mathrm{E}\,\theta^*\right)}_{=0}+\mathrm{E}\left(\mathrm{E}\,\theta^*-\theta\right)^2=$$

$$=\mathrm{D}\,\theta^*+\left(\mathrm{E}\,\theta^*-\theta\right)^2$$

Здесь $\left(\mathrm{E}\,\theta^*-\theta\right)^2$ константа, поэтому $\mathrm{E}\left(\mathrm{E}\,\theta^*-\theta\right)^2=\left(\mathrm{E}\,\theta^*-\theta\right)^2$

Т. о. $\mathrm{MSE}\left(\theta^*\right)=\mathrm{D}\,\theta^*+\left(\mathrm{E}\,\theta^*-\theta\right)^2$

Первое слагаемое – это дисперсия, случайный разброс. Например, попадания при стрельбе разбросаны, дрожание рук при стрельбе

Второе слагаемое – это смещение в квадрате, систематическая ошибка, нарушена несмещенность. Продолжая аналогию, стрелок в среднем промахивается, прицел винтовки сдвинут

Само $\mathrm{MSE}\left(\theta^*\right)$ – это общая ошибка (насколько в среднем промахивается, среднее расстояние до цели)

<u>Вывод</u>: Учитывая $\mathrm{D}\,\theta^*=\mathrm{MSE}\left(\theta^*\right)-\left(\mathrm{E}\,\theta^*-\theta\right)^2$, заметим, иногда небольшое смещение позволяет сильно снизить дисперсию → итоговая ошибка (MSE) становится меньше

Замечание. Т. е. предложенная ранее несмещенная оценка не обязательно оптимальная

ЭФФЕКТИВНАЯ ОЦЕНКА

Еще один подход к оптимальному оцениванию

Определение. *Эффективная оценки параметра* θ^* – это несмещённая оценка, имеющая минимальную дисперсию среди всех несмещённых оценок параметра

Т. е. если для одного и того же параметра можно предложить несколько несмещенных оценок, то предпочтение следует отдать той, которая имеет меньшую дисперсию

Пример

Пусть дана выборка $X_1,\ldots,X_n\sim \mathrm{N}_{\mu,\sigma}$ и σ известно

Рассмотрим полученные ранее различные оценки среднего:

<u>Выборочное среднее</u>

$$\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i\Rightarrow \mathrm{D}\frac{1}{n}\sum_{i=1}^{n}X_i=\frac{1}{n^2}\sum_{i=1}^{n}\mathrm{D}\,X_i=\frac{\sigma^2}{n}$$

<u>Выборочная медиана</u>

Выпишем (без вывода) асимптотическую дисперсию медианы

$$\mathrm{D}\,\bar{m}_e\approx\frac{1}{4nf^2\left(\mu\right)}=\frac{\pi\sigma^2}{2n}$$

Т. о. получаем, что выборочное среднее имеет меньшую дисперсию

<u>Иллюстрация 2</u>

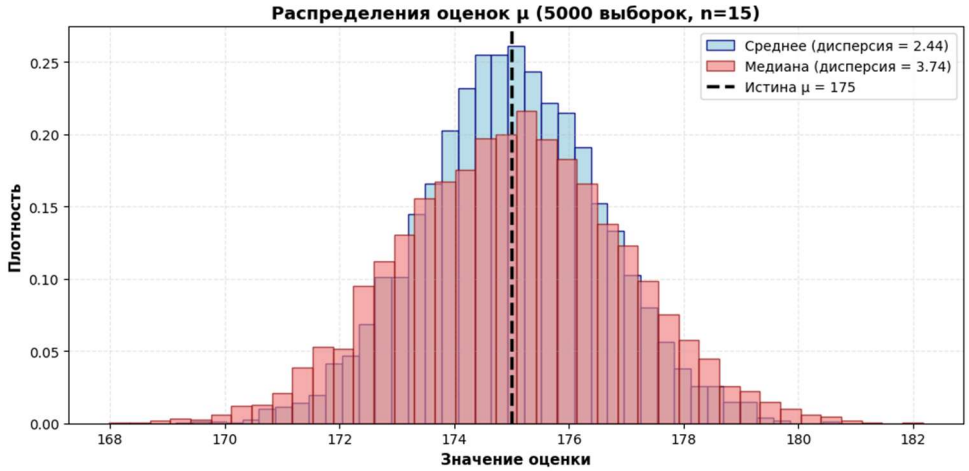

- Обе оценки несмещённые (пик обоих распределений около μ)
- Распределение среднего уже (меньше дисперсия)
- Распределение медианы шире (больше дисперсия)
- Для нормального распределения *среднее эффективнее медианы*

Пример

Пусть дана выборка $X_1,\ldots,X_n\sim \mathrm{U}_{[\mu-a,\mu+a]}$, μ – середина интервала и математическое ожидание. При этом $\mathrm{D}\,X_i=\frac{\left(\mu+a-\left(\mu-a\right)\right)^2}{12}=\frac{a^2}{3}$

<u>Выборочное среднее</u>

$$\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i\Rightarrow \mathrm{D}\frac{1}{n}\sum_{i=1}^{n}X_i=\frac{1}{n^2}\sum_{i=1}^{n}\mathrm{D}\,X_i=\frac{a^2}{3n}$$

<u>Выборочная медиана</u>

Выпишем (без вывода) асимптотическую дисперсию медианы $\mathrm{D}\,\overline{m}_e \approx \dfrac{a^2}{n}$

Еще одной оценкой среднего может служить полусумма концов отрезка (это понятно из задания интервала)

Полуразмах

$\tilde{X} = \dfrac{X_{\min} + X_{\max}}{2}$, без вывода запишем, что $\mathrm{D}\,\tilde{X} = \dfrac{a^2}{2(n+1)(n+2)}$

- Тем самым получаем, что полуразмах имеет самую маленькую дисперсию
- Для равномерного распределения *полуразмах эффективнее медианы и среднего*

Иллюстрация 3

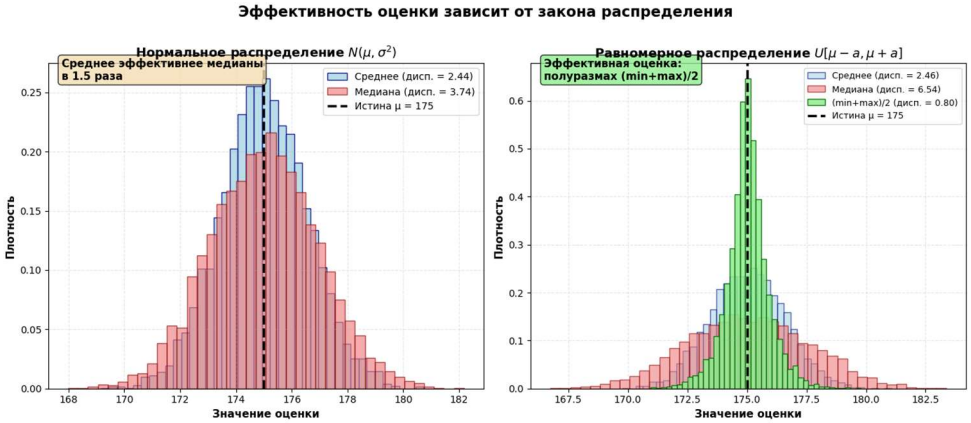

Замечание. Важно! Эффективность оценки зависит от вида закона распределения

Почему так?

- Нормальное распределение: плотность максимальна в центре → среднее использует информацию оптимально
- Равномерное распределение: плотность постоянна → вся информация о центре содержится в крайних точках. Среднее «размазывает» информацию по всем наблюдениям → менее эффективно

Вывод: Нет универсальной «лучшей» оценки, её нужно выбирать исходя из закона распределения данных

БАЙЕСОВСКИЙ И МИНИМАКСНЫЙ ПОДХОДЫ К СРАВНЕНИЮ ОЦЕНОК

Дадим представление еще о двух подходах к вопросу оптимальности оценок, связанные с «ценой» ошибки при замене точного значения параметра на его оценку

Определение. Функцию $L(\theta, \theta^*)$ характеризующую ошибку при замене θ на θ^* будем называть *функцией потерь*

Пример

Абсолютная функция потерь $L(\theta, \theta^*) = |\theta - \theta^*|$

Квадратичная функция потерь $L(\theta, \theta^*) = (\theta - \theta^*)^2$

Определение. Среднее значение функции потерь $R(\theta, \theta^*) = \mathrm{E}_\theta\left(L(\theta, \theta^*)\right)$ при фиксированном значении параметра θ называется *риском*

Заметим, что в таком подходе скрыта проблема: риск $R(\theta, \theta^*)$ зависит от неизвестного θ, и возникает вопрос выбора «лучшей» оценки

Рассмотрим два подхода в решении этой проблемы:

(1) У нас есть представление о том, какие значения θ более вероятны – задано априорное распределение $\pi(\theta)$

Тогда критерием качества выбирают средний риск

$r(\pi, \theta^*) = \int R(\theta, \theta^*)\pi(\theta)\,d\theta$

Это так называемый **байесовский** подход («готовимся к среднему случаю»)

(2) Мы ничего не знаем о θ

Тогда критерий максимальный риск $\sup\limits_{\theta} R(\theta, \theta^*)$

Это **минимаксный** подход («готовимся к худшему случаю»)

Замечание. Выбор между ними — это практическое решение, зависящее от контекста задачи, а не математическое

Поясним это на примерах

Пример (интуитивная аналогия)

Ситуация	Байесовский подход	Минимаксный подход

Прогулка: прогноз погоды	Считаем правильным → надеваем легкую куртку	Не верим → надеваем теплую куртку
Инвестиции	Вкладываем в активы с хорошей исторической доходностью → в среднем заработаем	Держим часть денег в надёжных облигациях → защита от краха рынка

Пример

Оценим вероятность успеха по одному испытанию $X \sim \mathrm{B}_p$ (Бернулли) (без подробных выводов)

Рассмотрим 3 оценки

- $\overline{p}_1 = X$ (в случае успеха $p=1$, иначе $p=0$). Риски $\overline{p}_1 \to R(p) = p(1-p)$
- $\overline{p}_2 = 0{,}5$ (вероятность всегда средняя), минимаксный подход. Риски $\overline{p}_2 \to R(p) = (0{,}5-p)^2$
- Полагаем, что априори все значения p равновероятны на $[0,1]$, т. е. имеют равномерное распределение, байесовский подход

После проведения опыта обновляем представление о распределении (формула Байеса). Строим плотность вероятности по формуле

$$f(p|X=x) = \frac{\mathrm{P}(X=x|p)f(p)}{\int_0^1 \mathrm{P}(X=x|p)f(p)dp}, \text{ где } \int_0^1 \mathrm{P}(X=x|p)f(p)dp \text{ – нор-}$$

мировочный множитель для функции распределения

Если $X=1$, то большие p более вероятны

$\mathrm{P}(X=1|p) = p$, $f(p)=1$, $f(p|X=x) = 2p$

Если $X=0$, то малые p более вероятны

$\mathrm{P}(X=1|p) = 1-p$, $f(p)=1$, $f(p|X=x) = 2(1-p)$

При квадратичной функции потерь $L = (\overline{p}-p)^2$ ищем средний риск

$$X=1 \Rightarrow \int_0^1 p \cdot 2p dp = \frac{2}{3},\ X=0 \Rightarrow \int_0^1 p \cdot 2(1-p)dp = \frac{1}{3}$$

Можно объединить в одну формулу $\overline{p}_3 = \dfrac{X+1}{3}$

Риск оценки $R(p, \overline{p}_3) = \mathrm{E}\left(\left(\dfrac{X+1}{3} - p\right)^2\right) = \dfrac{1-3p+3p^2}{9}$

<u>Иллюстрация 4</u>

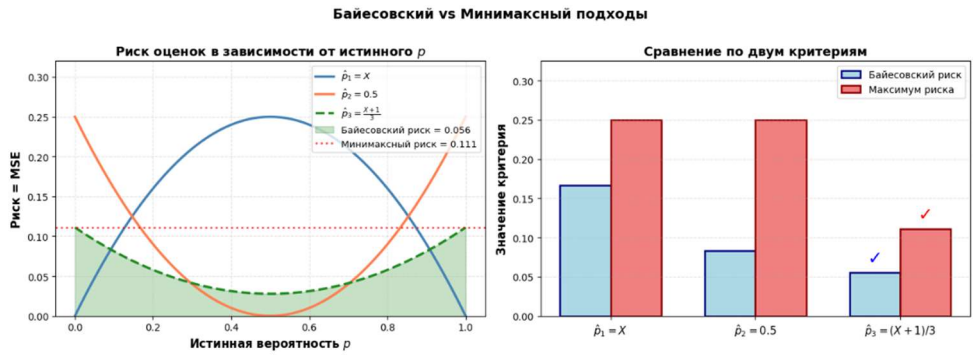

Комментарии к графикам

<u>Кривые риска</u>

1) $\overline{p}_1 \to R(p) = p(1-p)$. Это дисперсия бернуллиевской величины. При $p=0$ и $p=1$ исход детерминирован, риск = 0. При $p=0{,}5$ максимальная неопределённость, риск = 0,25
2) $\overline{p}_2 \to R(p) = (0{,}5-p)^2$. Всегда оцениваем 0,5. Ошибка минимальна, когда истинно $p=0{,}5$, риск = 0, и растет к границам
3) $\overline{p}_3 \to R(p) = \dfrac{1-3p+3p^2}{9}$. «Сглаженная» оценка. Никогда не говорит 0 или 1, поэтому ошибка на границах $\approx 0{,}11$, но и в центре не идеальна, при $p = 0{,}5 \approx 0{,}028$
4) Площадь под кривой при равномерном априорном распределении – это байесовский риск

<u>Сравнение критериев качества</u>

1) Байесовский риск (синий) – площадь под соответствующей кривой на левом графике
2) Максимум риска (красный) – Самая высокая точка на левом графике

<u>Вывод всей лекции</u>: «Лучшая» оценка зависит от запроса и того, как мы оцениваем ее качество