

ЛЕКЦИЯ 7

НЕКОТОРЫЕ РАСПРЕДЕЛЕНИЯ, ИСПОЛЬЗУЕМЫЕ В СТАТИСТИКЕ

Изучим некоторые абсолютно непрерывные распределения, тесно связанные с нормальным

ГАММА-РАСПРЕДЕЛЕНИЕ

В этом пункте нам понадобятся многие знания, полученные в теории вероятностей. Перед тем, как сформулировать определение гамма-распределения, напомним определение одной из важных функций, так называемой гамма-функции Эйлера

Определение. Гамма-функцией Эйлера называется функция

$$\Gamma(\lambda) = \int_0^{+\infty} t^{\lambda-1} e^{-t} dt$$

Замечание. Нам достаточно будет рассматривать гамма-функцию при $\lambda > 0$. При таких λ интеграл сходится.

Замечание. Отметим также, что при $\lambda > 0$ функция обладает свойством

$$\Gamma(\lambda + 1) = \lambda \Gamma(\lambda)$$

Лемма. $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$

Доказательство:

$$\Gamma\left(\frac{1}{2}\right) = \int_0^{+\infty} \frac{e^{-t}}{\sqrt{t}} dt = \left[\sqrt{t} = z, dz = \frac{dt}{2\sqrt{t}} \right] = 2 \int_0^{+\infty} e^{-z^2} dz = 2 \cdot \frac{\sqrt{\pi}}{2} = \sqrt{\pi} \quad (\text{использовали интеграл Эйлера-Пуассона})$$

зовали интеграл Эйлера-Пуассона)

Определение. Говорят, что случайная величина ξ имеет гамма-распределение с параметрами $\alpha > 0, \lambda > 0$, и пишут $\xi \sim \Gamma_{\alpha, \lambda}$, если ее плотность имеет вид

$$f_{\xi}(t) = \begin{cases} 0, & t < 0 \\ \frac{\alpha^{\lambda}}{\Gamma(\lambda)} t^{\lambda-1} e^{-\alpha t}, & t \geq 0 \end{cases}$$

То, что введенная функция является плотностью распределения, проверяется непосредственно с использованием замены $z = \alpha t$

Кроме того, легко видеть, что при $\lambda = 1$ гамма-распределение превращается в экспоненциальное распределение с параметром α

Иллюстрация 1

2





Иллюстрация 2



- Параметр α отвечает за форму кривой: определяет, будет ли она убывающей (как экспонента) или иметь колоколообразный вид с пиком
- Параметр λ отвечает за масштаб: определяет, насколько быстро происходит процесс. Он сжимает или растягивает кривую вдоль оси, не меняя её принципиальной формы

Сформулируем без доказательства леммы, которая понадобится нам для введения следующего важного распределения

Лемма. Пусть $\xi_1 \sim \Gamma_{\alpha, \lambda_1}, \xi_2 \sim \Gamma_{\alpha, \lambda_2}$ две независимые случайные величины. Тогда $\xi_1 + \xi_2 \sim \Gamma_{\alpha, \lambda_1 + \lambda_2}$

Лемма. Пусть случайные величины $\xi_1, \xi_2, \dots, \xi_n$ независимые в совокупности, причем $\xi_i \sim \Gamma_{\alpha, \lambda_i}, i \in \{1, 2, \dots, n\}$.

Тогда $S_n = \xi_1 + \xi_2 + \dots + \xi_n \sim \Gamma_{\alpha, \lambda_1 + \lambda_2 + \dots + \lambda_n}$

Лемма. Пусть случайная величина $\xi \sim N_{0,1}$. Тогда ξ^2 имеет распределение $\Gamma_{\frac{1}{2}, \frac{1}{2}}$

РАСПРЕДЕЛЕНИЕ χ^2 ПИРСОНА


Из приведенных выше лемм следует следующее утверждение

Лемма. Если случайные величины $\xi_1, \xi_2, \dots, \xi_n$ независимые в совокупности и имеют стандартное нормальное распределение $N_{0,1}$, то случайная величина $\chi_k^2 = \xi_1^2 + \xi_2^2 + \dots + \xi_n^2$ имеет распределение $\Gamma_{\frac{1}{2}, \frac{k}{2}}$

Определение. Распределение суммы квадратов k независимых в совокупности случайных величин со стандартным нормальным распределением называется распределением «хи-квадрат» χ^2 с k степенями свободы и обозначается H_k

Т. к. $H_k = \Gamma_{\frac{1}{2}, \frac{k}{2}}$, то плотность имеет вид $f_{\chi^2}(t) = \begin{cases} 0, t < 0 \\ \frac{1}{2^{\frac{k}{2}}} \cdot \frac{\alpha^{\frac{k}{2}}}{\Gamma(\frac{k}{2})} t^{\frac{k}{2}-1} e^{-\frac{t}{2}}, t \geq 0 \end{cases}$

Иллюстрация 3



Лемма. Пусть $\chi_k^2 \sim H_k, \chi_m^2 \sim H_m$ две независимые случайные величины. Тогда $\chi_{k+m}^2 = \chi_k^2 + \chi_m^2 \sim H_{k+m}$

Доказательство:

Т. к. $\chi_k^2 \sim H_k = \Gamma_{\frac{1}{2}, \frac{k}{2}}, \chi_m^2 \sim H_m = \Gamma_{\frac{1}{2}, \frac{m}{2}}$ и они независимы, то, согласно со-

ответствующей лемме, о гамма-распределениях имеем

$$\chi_k^2 + \chi_m^2 = \Gamma_{\frac{1}{2}, \frac{k+m}{2}} = H_{k+m}$$

Вычислим моменты этого распределения

Лемма. Пусть $\chi_k^2 \sim H_k$. Тогда $E \chi_k^2 = k, D \chi_k^2 = 2k$

Доказательство:

Если $\xi_1 \sim N_{0,1}$, то, $E \xi_1^2 = 1, D \xi_1^2 = E \xi_1^4 - (E \xi_1^2)^2 = 2$

По свойства математического ожидания и дисперсии

$$E \chi_k^2 = E(\xi_1^2 + \xi_2^2 + \dots + \xi_n^2) = k E \xi_1^2 = k$$

$$D \chi_k^2 = D(\xi_1^2 + \xi_2^2 + \dots + \xi_n^2) = k D \xi_1^2 = 2k$$

Лемма. Пусть случайные величины $\xi_1, \xi_2, \dots, \xi_n$ независимы в совокупности и имеют распределение $N_{\mu, \sigma}$, тогда случайная величина

$$\chi_k^2 = \sum_{i=1}^k \left(\frac{\xi_i - \mu}{\sigma} \right)^2 \text{ имеет распределение } H_k$$

Доказательство:

$$\text{Если } \xi_i \sim N_{\mu, \sigma} \Rightarrow \frac{\xi_i - \mu}{\sigma} \sim N_{0,1}, \text{ то } E \xi_1^2 = 1, D \xi_1^2 = E \xi_1^4 - (E \xi_1^2)^2 = 2$$

РАСПРЕДЕЛЕНИЕ СТЬЮДЕНТА


Определение. Пусть случайные величины $\xi_0, \xi_1, \xi_2, \dots, \xi_k$ независимы в совокупности и имеют со стандартное нормальное распределение $N_{0,1}$. Распределение случайной величины

$$t_k = \frac{\xi_0}{\sqrt{\frac{1}{k}(\xi_1^2 + \xi_2^2 + \dots + \xi_k^2)}} = \frac{\xi_0}{\sqrt{\frac{\chi_k^2}{k}}} \text{ называется распределением Стьюдента с } k \text{ степенями свободы и обозначается } T_k$$

Можно показать, что что плотность случайной величины, имеющей распределение Стьюдента, равна

$$f_{t_k}(t) = \frac{\Gamma\left(\frac{k+1}{2}\right)}{\sqrt{\pi k} \Gamma\left(\frac{k}{2}\right)} \left(1 + \frac{t^2}{k}\right)^{-\frac{k+1}{2}}$$

Иллюстрация 4



Лемма. Пусть случайная величина t_k имеет распределение Стьюдента T_k с k степенями свободы. Тогда случайная величина $-t_k$ тоже имеет распределение Стьюдента T_k с k степенями свободы

Доказательство:

$$F_{-t_k}(x) = P(-t_k < x) = P(t_k > -x) = \int_{-x}^{+\infty} f_{t_k}(t) dt$$

Сделаем замену $p = -t$. Тогда в силу четности $f_{t_k}(t)$ получим

$$F_{-t_k}(x) = - \int_x^{-\infty} f_{t_k}(-p) dp = - \int_{-\infty}^x f_{t_k}(p) dp = F_{t_k}(x)$$

Лемма. Распределение Стьюдента T_k слабо сходится к стандартному нормальному распределению $N_{0,1}$ при $k \rightarrow +\infty$

Доказательство:

Пусть случайные величины $\xi_0, \xi_1, \xi_2, \dots, \xi_k$ независимы в совокупности и имеют со стандартное нормальное распределение $N_{0,1}$. Как уже было отмечено $E \xi_1^2 = 1$, а тогда, по закону больших чисел

$$\frac{\chi_k^2}{k} = \frac{\xi_1^2 + \xi_2^2 + \dots + \xi_n^2}{k} \xrightarrow[k \rightarrow \infty]{P} 1$$

Но тогда, согласно свойствам сходимости по вероятности,

$$t_k = \frac{\xi_0}{\sqrt{\frac{\chi_k^2}{k}}} \xrightarrow[k \rightarrow \infty]{P} \xi_0$$

откуда и следует слабая сходимость. Т. е.

$$t_k \xrightarrow[k \rightarrow \infty]{d} \xi_0 \sim N_{0,1}$$


РАСПРЕДЕЛЕНИЕ ФИШЕРА

Распределение Фишера тесно связано с теми распределениями, что мы только что рассмотрели, но не связано с задачами, решаемыми в ближайших лекциях. Мы будем использовать распределение Фишера при решении задач проверки гипотез

Определение. Пусть независимые случайные величины $\xi \sim N_{k_1}, \eta \sim N_{k_2}$. Тогда распределение случайной величины $F_{k_1, k_2} = \frac{\xi/k_1}{\eta/k_2}$

называется распределением Фишера с k_1 и k_2 степенями свободы

Иллюстрация 5



Отметим без доказательства свойство

Лемма. Если случайная величина имеет распределение Стюдента с k степенями свободы T_k , то её квадрат имеет распределение Фишера с параметрами $1, k$, т. е. $T_k^2 \sim F_{1, k}$

Теперь можно переходить к обсуждению интервального оценивания

ИНТЕРВАЛЬНОЕ ОЦЕНИВАНИЕ

В предыдущих лекциях мы поговорили про так называемое точечное оценивание неизвестных параметров генеральной совокупности. Нами были изучены методы моментов и максимального правдоподобия для получения этих оценок, а также было сказано несколько слов про их свойства: несмещенность, состоятельность, асимптотическую нормальность. Более того, мы немного пролили свет на то, как можно сравнивать оценки, определили понятие эффективной. Однако, точечное оценивание – не единственно возможный вариант. В следующих двух лекциях мы займемся так называемым интервальным оцениванием – построением доверительных интервалов, в которых, с наперед заданной вероятностью, содержится интересующая нас величина

ТОЧНЫЕ ДОВЕРИТЕЛЬНЫЕ ИНТЕРВАЛЫ

Пусть у нас, как обычно, имеется выборка $X_1, \dots, X_n$ из семейства распределений $\mathcal{F}_\theta$, которое известным образом зависит от неизвестного параметра θ из некоторого множества Θ

Определение. Пусть $0 < \varepsilon < 1$.

Интервал $(\theta^-; \theta^+) = (\theta^-(X, \varepsilon); \theta^+(X, \varepsilon))$, где θ^-, θ^+ – статистики, называется доверительным интервалом уровня доверия (или надежности) $1 - \varepsilon$, если для любого $\theta \in \Theta$ выполняется $P_\theta(\theta^- < \theta < \theta^+) \geq 1 - \varepsilon$

Итак, доверительный интервал уровня доверия $1 - \varepsilon$ – это интервал, который с вероятностью не меньше, чем $1 - \varepsilon$, покрывает (содержит) интересующий нас параметр

Замечание. Почему берется неравенство, а не просто равенство? Действительно, для абсолютно непрерывных распределений вопрос о вероятности, равной $1 - \varepsilon$, имеет место для любого $\varepsilon \in (0; 1)$, т. е. каждая такая вероятность достигается хотя бы потому, что функция

распределения абсолютно непрерывного распределения непрерывна.

Ситуация совершенно меняется в случае, если рассматривается дискретное распределение. Скажем, для случайной величины ξ с распределением Бернулли $B_{0,5}$ с параметром $p = 0,5$, равенство $P(a < \xi < b) = 0,75$ невозможно в принципе ни для каких $a, b \in \mathbb{R}$. При этом если заменить равенство на неравенство $\geq$, все становится вполне осмысленным

Определение. Если в определении доверительного интервала вместо неравенства достигается равенство, т. е. $P_\theta(\theta^- < \theta < \theta^+) = 1 - \varepsilon$, то доверительный интервал называется точным

Замечание. Ясно, что тем доверительный интервал лучше, чем он уже. Да и вообще, конструкция оправдана, если только

$\theta^+ - \theta^- \xrightarrow[n \rightarrow \infty]{P} 0$, т. е. если длина интервала с ростом значений n стремится к нулю (по вероятности)

Построение точных доверительных интервалов – дело непростое

Приведем пример, иллюстрирующий общую идею этого построения

Точный доверительный интервал для $U_{0,\theta}$ при известной дисперсии

Пусть $X_1, \dots, X_n \sim U_{0,\theta}$ (имеет равномерное распределение), где параметр θ неизвестен и $\theta \in \Theta = (0; +\infty)$

Для этого рассмотрим вспомогательные случайные величины $Y_i = \frac{X_i}{\theta}$.

Согласно свойствам линейных преобразований от случайных величин, новые случайные величины имеют равномерное распределение $U_{0,1}$. В частности, важно то, что их распределение теперь не зависит от θ
Распределение n -ой порядковой статистики имеет распределение

$$F_{Y^{(n)}}(t) = \begin{cases} 0, & t \leq 0 \\ t^n, & 0 < t \leq 1 \\ 1, & t > 1 \end{cases}$$

Найдем левую границу x интервала $(x, 1)$, для которого $P_\theta(x < Y^{(n)} < 1) = 1 - \varepsilon$

Это легко сделать, используя функцию распределения, ведь по уму $x > 0$, т. к. $Y^{(n)} \sim U_{0,1}$ и $P_\theta(x < Y^{(n)} < 1) = F_{Y^{(n)}}(1) - F_{Y^{(n)}}(x) = 1 - x^n$

Приравняв выражения, получим

$$1 - x^n = 1 - \varepsilon \Leftrightarrow x^n = \varepsilon \Leftrightarrow x = \sqrt[n]{\varepsilon}$$

Значит, $P_\theta(\sqrt[n]{\varepsilon} < Y^{(n)} < 1) = 1 - \varepsilon$

Подставив вместо порядковой статистики $Y^{(n)}$ ее выражение

$Y^{(n)} = \frac{X^{(n)}}{\theta}$ и учитывая положительность θ и $X^{(n)}$ получаем

$$1 - \varepsilon = P_\theta(\sqrt[n]{\varepsilon} < Y^{(n)} < 1) = P_\theta\left(\sqrt[n]{\varepsilon} < \frac{X^{(n)}}{\theta} < 1\right) = P_\theta\left(X^{(n)} < \theta < \frac{X^{(n)}}{\sqrt[n]{\varepsilon}}\right)$$

Значит, интервал $(\theta^-(X, \varepsilon); \theta^+(X, \varepsilon)) = \left(X^{(n)} < \theta < \frac{X^{(n)}}{\sqrt[n]{\varepsilon}}\right)$

Обсудим вопрос стремления интервала к нулю при $n \rightarrow \infty$


Т. к. $\sqrt[n]{\varepsilon} \xrightarrow[n \rightarrow \infty]{} 1$, то согласно формуле Тейлора

$$1 - \frac{1}{\sqrt[n]{\varepsilon}} = 1 - \varepsilon^{-\frac{1}{n}} = 1 + \frac{1}{n} \ln \varepsilon + o\left(\frac{1}{n^2}\right)$$

Т. е. скорость стремления к 0 имеет порядок $\frac{1}{n}$

Протестируем полученный интервал численно

Иллюстрация 6



ОБЩИЙ ПРИНЦИП ПОСТРОЕНИЯ ДОВЕРИТЕЛЬНЫХ ИНТЕРВАЛОВ

Итак, общий принцип построения точных доверительных интервалов можно сформулировать в следующем виде:

1. Составляется случайная величина $T(X, \theta)$, распределение которой не зависит от параметра θ , и которая обратима по θ при фиксированной выборке X ;
2. Находятся квантили t_1 и t_2 распределения случайной величины T так, чтобы выполнялось равенство

$$P_{\theta}(t_1 < T(X, \theta) < t_2) = 1 - \varepsilon$$

3. Неравенство $t_1 < T(X, \theta) < t_2$ разрешается относительно θ , откуда и получается интересующий нас доверительный интервал

Несмотря на четкий алгоритм действий, сложность описанного подхода достаточно очевидна: совершенно непонятно, как найти «достойную» функцию $T(X, \theta)$, удовлетворяющую описанным условиям. В частности, как ее заставить не зависеть от θ ? Именно поэтому, а еще из-за предельных теорем, чаще строят так называемые асимптотические доверительные интервалы, о которых и пойдет речь далее