

ЛЕКЦИЯ 8

ПРЕОБРАЗОВАНИЕ НОРМАЛЬНЫХ ВЫБОРОК И ЛЕММА ФИШЕРА

Пусть $X_1, \dots, X_n \sim N_{0,1}$. В этом пункте мы будем рассматривать ее как вектор-столбец X , это будет существенно для матричных операций

Напоминание. Квадратная матрица A называется ортогональной, если $AA^T = A^T A = E$

Теорема. Пусть A – ортогональная матрица, а X – вектор-столбец из независимых в совокупности случайных величин, имеющих стандартное нормальное распределение. Тогда и координаты вектора $Y = AX$, независимы в совокупности и имеют стандартное нормальное распределение

Лемма. (Лемма Фишера) Пусть X – выборка из стандартного нормального распределения $N_{0,1}$, A – ортогональная матрица, $Y = AX$. Тогда при любом $k \in \{1, 2, \dots, n-1\}$ случайная величина

$T(X) = \sum_{i=1}^n X_i^2 - (Y_1^2 + \dots + Y_k^2)$ не зависит от $Y_1, \dots, Y_k$ и имеет распределение N_{n-k}

Доказательство:

Ортогональное преобразование не меняет длины вектора, т. е. $X_1^2 + \dots + X_n^2 = Y_1^2 + \dots + Y_n^2$

Тогда

$$T(X) = \sum_{i=1}^n X_i^2 - (Y_1^2 + \dots + Y_k^2) = \sum_{i=1}^n Y_i^2 - (Y_1^2 + \dots + Y_k^2) = Y_{k+1}^2 + \dots + Y_n^2$$

Поскольку $Y_1, \dots, Y_n \sim N_{0,1}$ и независимы в совокупности, то $T(X) = Y_{k+1}^2 + \dots + Y_n^2$ имеет распределение хи-квадрат с $n-k$ степенями свободы и не зависит от $Y_1, \dots, Y_k$

Важным следствием леммы Фишера является следующая теорема

Теорема. Пусть $X_1, \dots, X_n \sim N_{\mu, \sigma}$ и независимы, тогда:

$$1. \quad \frac{n-1}{\sigma^2} \bar{\sigma}^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim N_{n-1}$$

$$2. \quad \text{Случайные величины } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \text{ и } \bar{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

независимы

Замечание. Обращают внимание на себя следующие моменты. Во-первых, вопреки определению χ^2 распределения, рассматриваемая сумма содержит не $n-1$, а n слагаемых. Во-вторых, эти слагаемые вроде как заведомо зависимы, т. к. в каждом из них присутствует величина $\bar{X}$. В-третьих, все эти слагаемые хоть и одинаково распределены, но имеют вовсе не стандартное нормальное распределение $N_{0,1}$

Ничем не лучше с точки «здравого смысла» и второй пункт рассматриваемой теоремы. Как эти случайные величины могут быть независимыми, если выборочное среднее $\bar{X}$ явным образом входит в определение несмещенной выборочной дисперсии $\bar{\sigma}^2$?

Однако, эта теорема может быть доказана (мы это доказательство опустим)

ТОЧНЫЙ ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ ДЛЯ ПАРАМЕТРОВ НОРМАЛЬНОГО ЗАКОНА РАСПРЕДЕЛЕНИЯ

Сформулированная теорема поможет нам построить точные доверительные интервалы для параметров нормального распределения при различных предположениях о последних

Лемма. Пусть $X_1, \dots, X_n \sim N_{\mu, \sigma}$ и независимы в совокупности. Тогда:

1. Случайная величина $\sqrt{n} \frac{\bar{X} - \mu}{\sigma}$ имеет стандартное нормальное распределение $N_{0,1}$
2. Случайная величина $\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2$ имеет распределение N_n
3. Случайная величина $\sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 = \frac{n-1}{\sigma^2} \bar{\sigma}^2$ имеет распределение N_{n-1}

4. Случайная величина $\sqrt{n} \frac{\bar{X} - \mu}{\bar{\sigma}}$ имеет распределение Стюдента T_{n-1}

Доказательство теоремы опирается на сформулированные выше утверждения

Теперь можно перейти к построению доверительных интервалов. Будем следовать общей схеме построения ДИ и опираться на лемму

- Доверительный интервал для μ при известной дисперсии σ^2

СВ $\sqrt{n} \frac{\bar{X} - \mu}{\sigma} \sim N_{0,1}$ (пункт 1). Рассмотрим симметричный интервал

$(-c; c)$ и найдем вероятность попадания в него нашей СВ

$$P\left(-c < \sqrt{n} \frac{\bar{X} - \mu}{\sigma} < c\right) = \Phi_{0,1}(c) - \Phi_{0,1}(-c) = 2\Phi_{0,1}(c) - 1 = 1 - \varepsilon$$

$$2\Phi_{0,1}(c) = 2 - \varepsilon \Leftrightarrow \Phi_{0,1}(c) = 1 - \frac{\varepsilon}{2}$$

Находим квантиль $c = \tau_{1 - \frac{\varepsilon}{2}}$ уровня $1 - \frac{\varepsilon}{2}$ по таблице функции $\Phi_{0,1}(t)$ и

разрешаем неравенство относительно μ

$$P\left(\bar{X} - \tau_{1 - \frac{\varepsilon}{2}} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + \tau_{1 - \frac{\varepsilon}{2}} \frac{\sigma}{\sqrt{n}}\right) = 1 - \varepsilon$$

Иллюстрация 1

Квантиль $\tau_{0,975} = 1,96 : 1.9600$

Уровень доверия: 95%

Истинное среднее μ : 3.0

Известное σ : 2.0

Размер выборки $n = 30$:

Интервалов, покрывающих истинное среднее: 48/50

Фактический уровень доверия: 96%


Средняя ширина интервала: 1.4314

Размер выборки $n = 100$:

Интервалов, покрывающих истинное среднее: 48/50

Фактический уровень доверия: 96%

Средняя ширина интервала: 0.7840



Сравнение:

Ширина интервала для $n = 30$: 1.4314

Ширина интервала для $n = 100$: 0.7840

Длина доверительного интервала стремится к нулю со скоростью порядка

$$\frac{1}{\sqrt{n}}$$

- Доверительный интервал для μ при неизвестной дисперсии σ^2

Выполняем аналогичные построения, учитывая, что СВ $\sqrt{n} \frac{\bar{X} - \mu}{\bar{\sigma}}$

(пункт 4) имеет распределение Стюдента T_{n-1}

Пусть t_1 квантиль распределения T_{n-1} уровня $\frac{\varepsilon}{2}$, t_2 квантиль уровня

$1 - \frac{\varepsilon}{2}$. Из симметрии распределения можем записать $t_1 = -t_2$

$$P\left(-t_2 < \sqrt{n} \frac{\bar{X} - \mu}{\bar{\sigma}} < t_2\right) = 1 - \varepsilon \text{ и } P\left(\bar{X} - t_2 \frac{\bar{\sigma}}{\sqrt{n}} < \mu < \bar{X} + t_2 \frac{\bar{\sigma}}{\sqrt{n}}\right) = 1 - \varepsilon$$

Иллюстрация 2

Доверительный интервал с t -распределением Стьюдента
(дисперсия неизвестна, оценивается по выборке)

Размер выборки $n = 30$:

Степени свободы: 29

Квантиль t -распределения $t_{0,975}$: 2.0452

Выборочное $\bar{\sigma}$: 1.9652 (истинное $\sigma = 2.0$)

Интервалов, накрывающих истинное среднее: 47/50

Фактический уровень доверия: 94%

Средняя ширина интервала: 1.4676

Размер выборки $n = 100$:

Степени свободы: 99


Квантиль t -распределения $t_{0,975}$: 1.9842

Выборочное $\bar{\sigma}$: 1.9883 (истинное $\sigma = 2.0$)

Интервалов, накрывающих истинное среднее: 47/50

Фактический уровень доверия: 94%

Средняя ширина интервала: 0.7890



Для сравнения - квантиль нормального распределения: 1.9600





Иллюстрация 3



Выборка, где t -интервал шире: 6/10

Ключевые отличия от случая с известной дисперсией:

1. Используем t -распределение вместо нормального
2. Квантили t -распределения больше (особенно для малых n)
3. Используем выборочное $\bar{\sigma}$ вместо известного σ
4. Интервалы чаще получаются шире (учитываем неопределенность σ)
5. При больших n t -распределение $\rightarrow$ нормальному

- Доверительный интервал для σ^2 при известном μ

Учитывая, что СВ $\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2$ (пункт 2) имеет распределение Пирсона H_n построим доверительный интервал для дисперсии

Пусть c_1 квантиль распределения H_n уровня $\frac{\varepsilon}{2}$, c_2 квантиль уровня

$1 - \frac{\varepsilon}{2}$, $F_{\chi_n^2}$ функция распределения СВ χ_n^2 . Тогда

$$P\left(c_1 < \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 < c_2\right) = F_{\chi_n^2}(c_2) - F_{\chi_n^2}(c_1) = 1 - \frac{\varepsilon}{2} - \frac{\varepsilon}{2} = 1 - \varepsilon$$

Выражаем в неравенстве дисперсию


$$P\left(\frac{\sum_{i=1}^n (X_i - \mu)^2}{c_2} < \sigma^2 < \frac{\sum_{i=1}^n (X_i - \mu)^2}{c_1}\right) = 1 - \varepsilon$$

Иллюстрация 4

Истинная дисперсия: $\sigma^2 = 4.0$

$n = 30$: покрытие 94%, ср. ширина 4.511

$n = 100$: покрытие 100%, ср. ширина 2.285



Интервалы ассиметричны

Уменьшаются с ростом n со скоростью порядка $\frac{1}{\sqrt{n}}$

- Доверительный интервал для σ^2 при неизвестном μ

Не останавливаясь на подробных выкладках, которые опираются на 3 пункт леммы и выполняются аналогично предыдущему запишем окончательную формулу для доверительного интервала

$$P\left(\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{c_2} < \sigma^2 < \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{c_1}\right) = 1 - \varepsilon, \text{ где } c_1 \text{ и } c_2 \text{ квантили рас-}$$

пределения H_{n-1} уровня $\frac{\varepsilon}{2}$ и $1 - \frac{\varepsilon}{2}$ соответственно

Иллюстрация 5

График 1

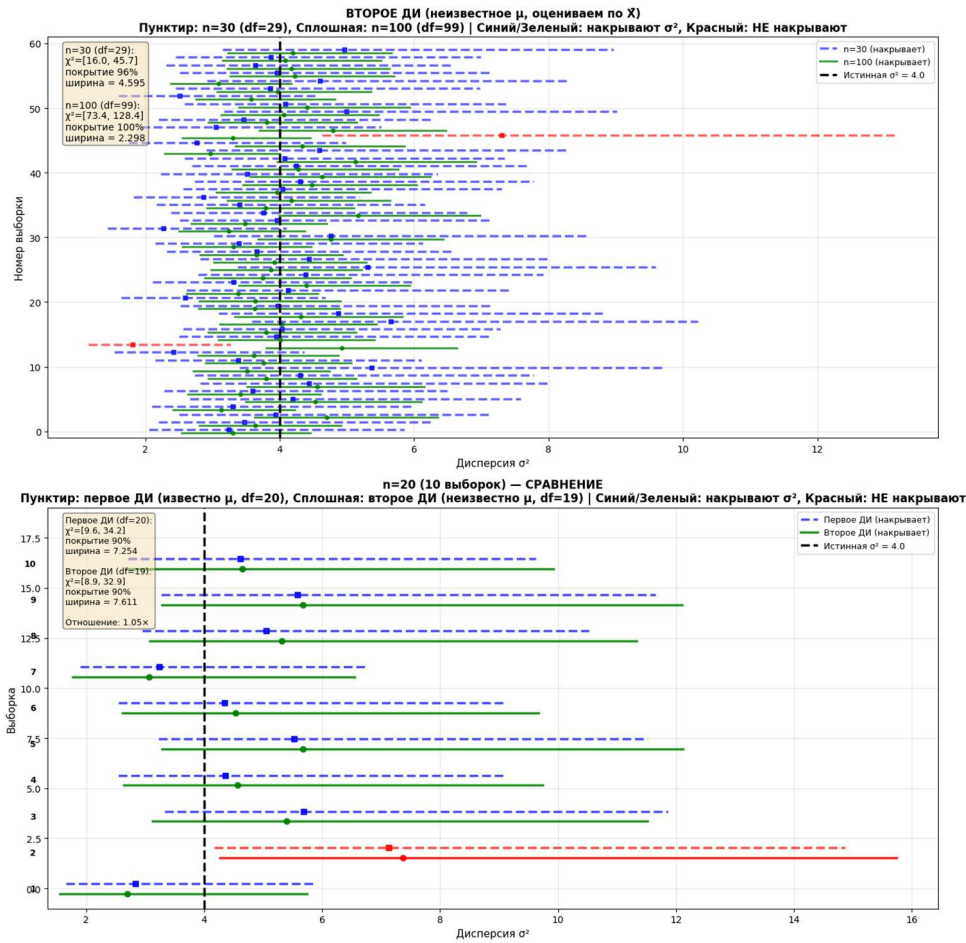
$n = 30$ (степеней свободы 29): χ^2 [16.0, 45.7], покрытие 96%, ширина 4.595

$n=100$ (степеней свободы 99): χ^2 [73.4, 128.4], покрытие 100%, ширина 2.298

График 2

Известное среднее (степеней свободы 20): χ^2 [9.6, 34.2], покрытие 90%, ширина 7.254

Неизвестное среднее (степеней свободы 19): χ^2 [8.9, 32.9], покрытие 90%, ширина 7.611



При неизвестном μ теряем 1 степень свободы, что увеличивает квантили χ^2 и как правило расширяет доверительный интервал

АСИМПТОТИЧЕСКИЕ ДОВЕРИТЕЛЬНЫЕ ИНТЕРВАЛЫ

Мы уже упоминали, что построить точный доверительный интервал довольно сложно. Потому встает вопрос что можно сделать если это не удастся

Определение. Пусть $0 < \varepsilon < 1$. Интервал $(\theta^-; \theta^+) = (\theta^-(X, \varepsilon); \theta^+(X, \varepsilon))$, где θ^-, θ^+ – статистики, называется асимптотическим доверительным интервалом уровня доверия $1 - \varepsilon$, если для любого $\theta \in \Theta$ выполняется $\liminf_{n \rightarrow \infty} P_\theta(\theta^- < \theta < \theta^+) \geq 1 - \varepsilon$

Замечание. Как мы видим, определение отличается от точного наличием предела. На самом деле, правильнее писать, не просто θ^-, θ^+ , а θ_n^-, θ_n^+ , так как в определении речь идет не об одном интервале, а о последовательности интервалов.

Замечание. Для тех, кого пугают слова или обозначения «нижнего предела» могут считать, что это совершенно классический предел. Больших неприятностей при этом, как правило, не возникает.

Замечание. Знак неравенства в определении асимптотического доверительного интервала объясняется ровно также, как и в случае точного доверительного интервала. Кстати, неплохо бы объяснить себе, а почему нельзя (или можно?) взять $\varepsilon = 0$? Каким в этом случае окажется асимптотический доверительный интервал? Плохо ли это?

Ну и, наконец, каково же главное отличие? А главное отличие заключается в том, что теперь написанное неравенство справедливо лишь в пределе. Так как в жизни бесконечности быть не может, то асимптотические доверительные интервалы имеет смысл рассматривать лишь при достаточно больших объемах выборки. Все это мы проиллюстрируем на примерах, описанных далее

АСИМПТОТИЧЕСКИЙ ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ ДЛЯ Exp_λ

Напомним, что $E_\lambda X_1 = \frac{1}{\lambda}$, $D_\lambda X_1 = \frac{1}{\lambda^2}$

По ЦПТ

$$Y_n = \frac{\sum_{i=1}^n X_i - n E_{\lambda} X_1}{\sqrt{n D_{\lambda} X_1}} = \sqrt{n} \frac{\bar{X} - \frac{1}{\lambda}}{\frac{1}{\lambda}} = \sqrt{n} (\lambda \bar{X} - 1) \xrightarrow[n \rightarrow +\infty]{d} Y \sim N_{0,1}$$

Значит по определению слабой сходимости

$$P_{\lambda}(-c < Y_n < c) = P_{\lambda}(-c < \sqrt{n}(\lambda \bar{X} - 1) < c) \xrightarrow[n \rightarrow +\infty]{} P_{\lambda}(-c < Y < c) = \Phi_{0,1}(c) - \Phi_{0,1}(-c) = 2\Phi_{0,1}(c) - 1 = 1 - \varepsilon$$

где $c = \tau_{1-\frac{\varepsilon}{2}}$ квантиль уровня $1 - \frac{\varepsilon}{2}$ стандартного нормального распре-

деления

Разрешаем неравенство относительно λ

$$\left(\frac{1}{\bar{X}} - \frac{\tau_{1-\frac{\varepsilon}{2}}}{\sqrt{n}\bar{X}} < \lambda < \frac{1}{\bar{X}} + \frac{\tau_{1-\frac{\varepsilon}{2}}}{\sqrt{n}\bar{X}} \right)$$

Иллюстрация 6




График 1 (разные λ):

$\lambda=0.5$: Покрытие=100.0%, средняя ширина=0.2786

$\lambda=1$: Покрытие=100.0%, средняя ширина=0.5659

$\lambda=2$: Покрытие=93.3% (1 из 15 интервалов красные), средняя ширина=1.1656

1. Не все покрывают истинное значение λ . Это нормально: при 95% доверии ожидается ~5% таких случаев

2. При малых λ (большое истинное среднее) $\rightarrow$ интервалы уже; при больших λ наоборот

График 2 (разные n , попарное сравнение):

$n=30$: Покрытие=93.3% (1 из 15 интервалов красные), средняя ширина=0.7173

$n=100$: Покрытие=93.3% (1 из 15 интервалов красные), средняя ширина=0.3945

1. С ростом объема выборки интервалы уже
2. Асимптотическая формула работает удовлетворительно даже при $n=30$

АСИМПТОТИЧЕСКИЙ ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ ДЛЯ $U_{0,\theta}$

$$\text{Напомним, что } E_{\theta} X_1 = \frac{\theta}{2}, D_{\theta} X_1 = \frac{\theta^2}{12}$$

По ЦПТ

$$Y_n = \frac{\sum_{i=1}^n X_i - n E_{\theta} X_1}{\sqrt{n D_{\theta} X_1}} = \sqrt{n} \frac{\bar{X} - \frac{\theta}{2}}{\sqrt{\frac{\theta^2}{12}}} = \sqrt{3n} \frac{2\bar{X} - \theta}{\theta} \xrightarrow[n \rightarrow +\infty]{d} Y \sim N_{0,1}$$

Аналогично предыдущему, пусть $c = \tau_{1-\frac{\varepsilon}{2}}$ квантиль уровня $1 - \frac{\varepsilon}{2}$ стан-

дартного нормального распределения

Разрешаем относительно θ неравенство

$$-\tau_{1-\frac{\varepsilon}{2}} < \sqrt{3n} \frac{2\bar{X} - \theta}{\theta} < \tau_{1-\frac{\varepsilon}{2}}$$

$$\text{Получим } \left(\frac{2\bar{X}}{1 + \frac{\tau_{1-\frac{\varepsilon}{2}}}{\sqrt{3n}}} < \theta < \frac{2\bar{X}}{1 - \frac{\tau_{1-\frac{\varepsilon}{2}}}{\sqrt{3n}}} \right)$$

Иллюстрация 7




График 1 (асимптотический ДИ для разных n):

$n=30$: Покрытие=93.3% (1 из 15 интервалов красные), средняя ширина=0.4371

$n=100$: Покрытие=93.3% (1 из 15 интервалов красные), средняя ширина=0.2290

1. С увеличением n ДИ уменьшается
2. Формула работает лучше при больших n

График 2 (сравнение методов, $n=50$):

Точный ДИ: Покрытие=93.3% (1 из 15 интервалов красные), средняя ширина=0.0606

Асимптотический ДИ: Покрытие=100.0% (0 из 15 интервалов красные), средняя ширина=0.3321

1. Точный интервал надёжнее – показывает лучшее покрытие и меньшую ширину
2. Точный всегда начинается с $X^{(n)}$, что логично: θ не может быть меньше максимального наблюдения. Асимптотический симметричен и может давать парадоксальные результаты

ОБЩИЙ ПРИНЦИП ПОСТРОЕНИЯ АСИМПТОТИЧЕСКИХ ДОВЕРИТЕЛЬНЫХ ИНТЕРВАЛОВ

Итак, общий принцип построения асимптотических доверительных интервалов можно сформулировать в следующем виде:

1. Составляется случайная величина $T(X, \theta)$, которая слабо сходится к распределению не зависящему от параметра θ , и которая обратима по θ при фиксированной выборке X ;
2. Находятся квантили t_1 и t_2 распределения случайной величины T так, чтобы выполнялось равенство

$$P_{\theta}(t_1 < T(X, \theta) < t_2) = 1 - \varepsilon$$

3. Неравенство $t_1 < T(X, \theta) < t_2$ разрешается относительно θ , откуда

и получается интересующий нас доверительный интервал

Давайте резюмируем. В этой лекции мы научились строить как доверительные, так и асимптотические доверительные интервалы для параметров различных распределений. Доверительный интервал накрывает истинный параметр с заданной вероятностью. Можно утверждать, что в некотором смысле он даже оценивает абсолютную погрешность (конечно, с заданным уровнем доверия) конкретного значения над истинным значением параметра. Кроме того, он часто показывает и погрешность, с которой заданная точечная оценка (особенно, когда она является серединой интервала) приближает истинное значение