


ЛЕКЦИЯ 10

НЕПАРАМЕТРИЧЕСКИЕ КРИТЕРИИ

Параметрические критерии удобны и часто эффективны, но их применение требует знания закона распределения или хотя бы достаточно сильных предположений о нем. На практике эти предположения нередко сомнительны: данные могут быть порядковыми, иметь выбросы, сильную асимметрию или тяжелые хвосты. В таких случаях используют непараметрические критерии.

Под непараметрическими критериями обычно понимают критерии, которые либо совсем не зависят от конкретного вида распределения, либо требуют лишь слабых условий: непрерывности, симметрии, независимости и т. п.

Иллюстрация 1



КРИТЕРИЙ ЗНАКОВ

Пусть $X_1, \dots, X_n$ независимые наблюдения из непрерывного распределения. Требуется проверить гипотезу

$$H_0: m_e = m_0 \text{ (медиана)}$$

Рассмотрим знаки разностей $X_i - m_0$. Если H_0 верна и распределение непрерывно, то $P(X_i > m_0) = P(X_i < m_0) = \frac{1}{2}$. Поэтому число плюсов $s = \text{количество}\{i: X_i > m_0\}$ имеет биномиальное распределение $B_{n, \frac{1}{2}}$

Иллюстрация 2



Значения $X_i = m_0$ в непрерывном случае имеют вероятность 0; в вычислениях их обычно просто исключают

Отсюда следует критерий:

- 1) при $H_1: m_e > m_0$ отвергаем H_0 при больших s ;
- 2) при $H_1: m_e < m_0$ отвергаем H_0 при малых s ;
- 3) при $H_1: m_e \neq m_0$ отвергаем H_0 при слишком малых или слишком больших s

Пример

Пусть после вычитания m_0 из 12 наблюдений оказалось 10 положительных и 2 отрицательных значения. Тогда $s = 10$

Для правосторонней альтернативы p-value вычисляется как

$$P(B_{12, \frac{1}{2}}) \geq 10$$

Замечание. Критерий знаков чрезвычайно прост, но использует лишь знаки, а не величины отклонений. Поэтому он устойчив, но не всегда достаточно мощен

КРИТЕРИЙ УИЛКОКСОНА

Если хочется учесть не только знак отклонения, но и его величину, естественно перейти к ранговой процедуре

Пусть требуется проверить

$$H_0: \text{распределение симметрично относительно } m_0$$

Вычислим разности $d_i = X_i - m_0$ и отбросим нулевые. Оставшимся абсолютным значениям $|d_i|$ присвоим ранги $1, 2, \dots, m$. Затем суммируем ранги, соответствующие положительным разностям:

W^+ = сумма рангов положительных d_i

Если H_0 верна, то знаки «плюс» и «минус» среди рангов должны распределяться достаточно случайно. Слишком большое или слишком малое значение W^+ свидетельствует против H_0

Иллюстрация 3

Схема для критерия Уилкоксона

i	d_i	$ d_i $	ранг $ d_i $	знак
1	2	2	2	+
2	-5	5	5	-
3	1	1	1	+
4	-3	3	3	-
5	4	4	4	+

Сумма положительных рангов: $W^+ = 7$ Сумма отрицательных рангов: $W^- = 8$

Идея критерия: сравниваем суммы рангов для положительных и отрицательных разностей.

Для малых объемов выборки распределение статистики W^+ табулировано

Для больших m используют нормальную аппроксимацию

Пусть $I_i = \begin{cases} 1, & \text{если ранг } i \text{ попал в } W^+ \\ 0, & \text{иначе} \end{cases}$, тогда $W^+ = \sum_{i=1}^m i \cdot I_i$

При справедливой H_0 : $E(I_i) = \frac{1}{2}$, поэтому $E(W^+) = \frac{1}{2} \sum_{i=1}^m i = \frac{m(m+1)}{4}$.

А $D(I_i) = \frac{1}{2} \left(1 - \frac{1}{2}\right)$ (распределение Бернулли), значит,

$$D(W^+) = \frac{1}{4} \sum_{i=1}^m i^2 = \frac{m(m+1)(2m+1)}{4 \cdot 6}$$

Тогда $Z = \frac{W^+ - E(W^+)}{\sqrt{D(W^+)}} \sim N_{0,1}$

Замечание. Критерий Уилкоксона для одной выборки обычно оказывается мощнее критерия знаков, потому что использует больше информации о данных

Пример

Если после ранжирования модулей отклонений положительным разностям соответствует сумма рангов 61, а по формулам $E(W^+) = 45$ и

$$D(W^+) = 71,25, \text{ то } Z_{\text{набл}} = \frac{61 - 45}{\sqrt{71,25}} \approx 1,90$$

Дальнейшее решение принимается по обычным правилам нормального критерия

КРИТЕРИЙ МАННА–УИТНИ

Пусть имеются две независимые выборки

$$X_1, \dots, X_m, \quad Y_1, \dots, Y_n$$

Требуется проверить, одинаково ли расположены соответствующие распределения. В простейшей постановке проверяется

H_0 : распределения совпадают

H_1 : одно распределение в среднем сдвинуто относительно другого

Объединим обе выборки и проранжируем все $m+n$ наблюдений, расположив их по возрастанию

Иллюстрация 4

Иллюстрация к критерию Манна-Уитни

Выборка X:

5

7

Выборка Y:

1

3

6

Объединяем выборки и упорядочиваем по возрастанию

Значения:

1

3

5

6

7

Группа:

Y

Y

X

Y

X

Ранги:

ранг 1

ранг 2

ранг 3

ранг 4

ранг 5

Для выборки X получаем ранги [3, 5], поэтому сумма рангов $R_X = 8$.

Если одна выборка систематически больше другой, её элементы получают более высокие ранги.

Обозначим через R_X сумму рангов элементов первой выборки. Если выборка в среднем содержит большие значения, то ее элементы будут

чаще стоять ближе к концу общего вариационного ряда, значит R_X будет большим. Но сама сумма рангов еще не очень удобна, потому что она зависит от размеров выборок. Поэтому из нее строят более специальную статистику. Статистика Манна–Уитни определяется как число “побед” одной выборки над другой

Статистика Манна–Уитни строится следующим образом. Вводим индикатор

$$I(X_i > Y_j) = \begin{cases} 1, & \text{если } X_i > Y_j \\ 0, & \text{если } X_i \leq Y_j \end{cases} \text{ и считаем } U_X = \sum_{i=1}^m \sum_{j=1}^n I(X_i > Y_j) \text{ (сколько раз}$$

элемент X оказался больше элемента Y)

$$\text{Аналогично можно определить } U_Y = \sum_{i=1}^m \sum_{j=1}^n I(Y_j > X_i)$$

Если нет совпадений, то $U_X + U_Y = mn$

Если бы все элементы X стояли в общем ряду самыми первыми, то их ранги были бы $1, 2, \dots, m$, а их сумма $\frac{m(m+1)}{2}$. Это как бы “базовая” сумма

Каждый раз, когда какой-то элемент X оказывается правее одного элемента Y сумма рангов X увеличивается на 1. Общее число таких обгонов и есть

$$U_X. \text{ Тем самым } R_X = U_X + \frac{m(m+1)}{2} \Rightarrow U_X = R_X - \frac{m(m+1)}{2}$$

Вывод. Если первая группа систематически получает большие ранги, чем вторая, то статистика U оказывается слишком большой, и H_0 отвергается в пользу предположения о сдвиге

Не останавливаясь на доказательствах, отметим, что при справедливой H_0 в случае непрерывных распределений без совпадающих наблюдений

$$EU = \frac{mn}{2}, \text{ а } DU = \frac{mn(m+n+1)}{12}$$

И для больших m и n используют статистику

$$Z = \frac{U - E(U)}{\sqrt{D(U)}} \sim N_{0,1}, \text{ которая приблизительно имеет стандартное нормальное}$$

распределение

Замечание. Ранговые критерии работают не с самими значениями наблюдений, а с их относительным положением. Поэтому они заметно устойчивее к выбросам и монотонным преобразованиям шкалы

Замечание. Дадим некоторые ориентиры для выбора непараметрического критерия

- 1) Критерий знаков – самый грубый, но и самый устойчивый
- 2) Критерий Уилкоксона использует ранги и потому обычно мощнее
- 3) Критерий Манна–Уитни – естественный аналог двух выборочного критерия для независимых совокупностей
- 4) Если данные парные, нужно применять критерии для зависимых наблюдений; если выборки независимы – для независимых

Иллюстрация 5



КРИТЕРИИ СОГЛАСИЯ

До сих пор мы в основном проверяли гипотезы о числовых параметрах уже выбранного закона распределения. Но часто сначала нужно ответить на более грубый вопрос: согласуются ли наблюдаемые данные с предполагаемым законом вообще. Для этого служат критерии согласия. Типичная постановка выглядит так:

H_0 : распределение выборки имеет вид F_0


H_1 : распределение выборки отлично от F_0

Если F_0 зависит от неизвестных параметров, то сначала эти параметры оценивают по выборке

КРИТЕРИИ СОГЛАСИЯ ПИРСОНА

Для формулировки гипотезы о вид закона распределения логичнее всего построить гистограмму и визуально определить предположение о каком законе мы будем проверять. Здесь также могут понадобиться оценки параметров закона

Иллюстрация 6




При этом диапазон значений разбит на k непересекающихся интервалов $\Delta_1, \dots, \Delta_k$. Обозначим через v_i фактическое число наблюдений, попавших в интервал Δ_i

При этом если H_0 верна, то ожидаемое число наблюдений в этом интервале равно np_i , где $p_i = P(X \in \Delta_i | H_0)$. Вероятности p_i вычисляют по известной формуле $p_i = F_0(x_i) - F_0(x_{i-1})$, где $\Delta_i = [x_{i-1}; x_i]$

Сравнение фактических частоты с ожидаемыми, лежит в основе построения статистики

Иллюстрация 7



Критерий Пирсона сопоставляет высоты столбиков эмпирической гистограммы с ожидаемыми высотами при верной H_0 . Чем сильнее они расходятся, тем больше значение статистики

Критерий Пирсона вычисляется по формуле

$$\chi^2 = \sum_{i=1}^k \frac{(v_i - np_i)^2}{np_i} \text{ с числом степеней свободы } r = k - s - 1, \text{ где } s \text{ число}$$

параметров закона, оцениваемых по выборке

Замечание. На практике обычно требуют, чтобы все ожидаемые частоты np_i были не слишком малы. Часто используют эмпирическое правило $np_i \geq 5$. Если это не так, соседние интервалы объединяют

В итоге алгоритм критерия Пирсона выглядит следующим образом:

- Выбирается разбиение на интервалы
- Подсчитываются наблюдаемые частоты v_i . При необходимости некоторые интервалы объединяются
- Находятся ожидаемые вероятности $p_i = F_0(x_i) - F_0(x_{i-1})$ и частоты np_i при справедливой H_0


$$\chi^2_{\text{набл}} = \frac{\sum_{i=1}^k (v_i - np_i)^2}{np_i}$$

- Вычисляется статистика $\chi^2_{\text{набл}}$
- Гипотеза H_0 отвергается, если $\chi^2_{\text{набл}} \in W = [\chi^2_{1-\alpha, r}; +\infty)$

КРИТЕРИЙ КОЛМОГОРОВА

Другой путь – не группировать данные, а сравнить эмпирическую функцию распределения с теоретической

Иллюстрация 8



Пусть $F_n(x)$ – эмпирическая функция распределения выборки, а $F_0(x)$ – функция распределения, задаваемая гипотезой H_0 . Рассмотрим статистику

$$D_n = \sup_x |F_n(x) - F_0(x)|$$

Она измеряет наибольшее вертикальное расстояние между двумя функциями распределения

Если H_0 задает распределение полностью и однозначно (параметры закона определенно известны), а $F_0(x)$ непрерывна, то распределение величины $\sqrt{n}D_n$ (статистика Колмогорова) не зависит от $F_0(x)$. Более того, $P(\sqrt{n}D_n \leq t) \xrightarrow{n \rightarrow \infty} K(t)$

где $K(t)$ – функция распределения Колмогорова, которая описывает предельное распределение статистики Колмогорова

Замечание. Значения функции $K(t) = \begin{cases} 0, & t \leq 0 \\ 1 - 2 \sum_{k=1}^{\infty} (-1)^{k-1} e^{-2k^2 t^2}, & t > 0 \end{cases}$

обычно не вычисляют вручную по ряду, а берут из таблиц

Следовательно, критерий строят по правилу $W = [\tau_\alpha; +\infty)$, где τ_α – соответствующий квантиль распределения Колмогорова

Замечание. В классическом виде критерий Колмогорова применим к простой гипотезе (известен не только закон, но и его параметры). Если параметры же $F_0(x)$ оценивались по выборке, табличные критические значения меняются

СРАВНЕНИЕ КРИТЕРИЕВ СОГЛАСИЯ

Наиболее употребительными являются критерий Пирсона и критерий Колмогорова; выбор между ними зависит от природы данных, способа задания гипотезы и того, оцениваются ли параметры по выборке. Во всех критериях согласия логика одна и та же: если расхождение между эмпирическим поведением выборки и тем, что предсказывает H_0 , слишком велико, то гипотеза отвергается. Однако следует отметить некоторые различия в применении критериев

- Критерии Пирсона и Колмогорова имеют разную философию. Пирсон работает с группированными частотами. Он удобен, если данные уже разбиты по интервалам или если требуется анализировать дискретные категории
- Колмогоров использует полный порядок наблюдений и не требует группировки. Поэтому он особенно естественен для непрерывных распределений
- Результат критерия Пирсона может зависеть от выбранного разбиения на интервалы. У критерия Колмогорова такой проблемы нет, но он хуже работает в ситуациях, когда расхождение сосредоточено в хвостах и при этом важно именно интегральное отклонение частот
- Если параметры закона оцениваются по той же выборке, это необходимо учитывать в критических значениях и числе степеней свободы

Замечание. Как и раньше, отсутствие оснований отвергнуть H_0 не означает, что закон распределения установлен окончательно. Это лишь означает, что на выбранном уровне значимости выборка не противоречит H_0 слишком сильно