

ЛЕКЦИЯ 11

МОТИВАЦИЯ

Представьте ситуацию: Вы риелтор. Клиент спрашивает: «Сколько будет стоить квартира площадью 75 м² в этом районе?»

У вас есть данные по 200 проданным квартирам: площадь и цена. Как дать обоснованный ответ?

Интуитивный подход: посмотрю на похожие квартиры...

Научный подход: построю модель, которая обобщает все данные и даёт прогноз с оценкой точности


Т. е. Нужно найти *закономерность* – как в среднем меняется цена при изменении площади. Это и есть *регрессия*

Определение. Функцией регрессии случайной величины Y на X называется функция $E(Y|X=x)$, если соответствующее условное математическое ожидание существует

Линейная регрессия – это переход от данных к решению

Представьте, что вы нанесли на график 100 точек (площадь, цена). Вы увидите «облако» с восходящим трендом: чем больше площадь, тем выше цена

Иллюстрация 1



Сгенерировано 100 наблюдений

Задача: найти закономерность в этом облаке точек

Почему точки не лежат идеально на прямой

- Другие факторы – этаж, ремонт, вид из окна
- Случайность – срочность продажи, настроение покупателя
- Ошибки измерений – неточность в объявлении

Задача: провести через это облако *одну прямую*, которая лучше всего описывает тенденцию

МОДЕЛЬ ЛИНЕЙНОЙ РЕГРЕССИИ


Определение. Пусть дана выборка наблюдений $\{X_i, Y_i\}, i=1, \dots, n$, где Y_i – зависимая переменная, X_i – независимая переменная. Тогда назовем моделью простой линейной регрессии зависимость вида $Y_i = \theta_0 + \theta_1 X_i + \varepsilon_i, i=1, \dots, n$, где θ_0, θ_1 – неизвестные параметры, а ε_i – случайные ошибки

Предположения, которые обычно делают для классической линейной модели

- (1) Линейность по параметрам. Линейность относится к θ_0, θ_1 , а не к X . Можно использовать $X^2, \ln X, \dots$
- (2) Нулевое условное среднее для ошибок $E(\varepsilon_i | X_i) = 0, \forall i$ и как следствие $E(Y_i | X_i) = \theta_0 + \theta_1 X_i$
- (3) Разброс ошибок одинаков при всех значениях независимой переменной $D(\varepsilon_i | X_i) = \sigma^2 = \text{const}$
- (4) Ошибка одного наблюдения никак не связана с ошибкой для любого другого наблюдения $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, i \neq j$
- (5) Нормальность распределения ошибки $\varepsilon_i | X_i \sim N_{0, \sigma^2}$

Иллюстрация 2

Какая прямая лучше описывает данные?



Несколько прямых правдоподобно описывают данные

Нужен объективный критерий выбора

Замечание. Сохраняя линейность по параметрам, мы можем рассматривать в качестве лучшей альтернативы другие виды зависимостей. Например, параболическую регрессию $Y_i = \theta_0 + \theta_1 X_i + \dots + \theta_m X_i^m$ или еще более сложную $Y_i = \theta_1 \varphi_1(X_i) + \theta_2 \varphi_2(X_i) + \dots + \theta_m \varphi_m(X_i)$

ОЦЕНКА ПАРАМЕТРОВ МЕТОДОМ НАИМЕНЬШИХ КВАДРАТОВ

Продолжим рассмотрение простой линейной регрессии $Y_i = \theta_0 + \theta_1 X_i + \varepsilon_i$

Задача: найти θ_0, θ_1 так, чтобы прямая $Y = \bar{\theta}_0 + \bar{\theta}_1 X$ «наилучшим образом» описывала данные

Идея МНК: выбрать такую прямую, чтобы сумма квадратов вертикальных расстояний от точек до прямой была минимальна

$$S = \sum_{i=1}^n (Y_i - \bar{\theta}_0 - \bar{\theta}_1 X_i)^2$$

Почему квадраты?

- Штрафуем большие ошибки сильнее: отклонение на 10 хуже, чем два отклонения на 5

- Симметрия: неважно, выше точка или ниже – оба отклонения «плохие»
- Квадрат – гладкая функция, легко дифференцировать

Теорема. Пусть дана выборка наблюдений $\{X_i, Y_i\}, i=1, \dots, n$. Оценки коэффициентов линейной регрессии $Y = \bar{\theta}_0 + \bar{\theta}_1 X$ минимизирующие сумму $S = \sum_{i=1}^n (Y_i - \bar{\theta}_0 - \bar{\theta}_1 X_i)^2$ вычисляются по формулам

$$\bar{\theta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}, \bar{\theta}_0 = \bar{Y} - \bar{\theta}_1 \bar{X}$$

Доказательство:

$S = \sum_{i=1}^n (Y_i - \bar{\theta}_0 - \bar{\theta}_1 X_i)^2$ является функцией двух переменных θ_0, θ_1 . Вы-

числим частные производные

$$\begin{cases} \frac{\partial S}{\partial \theta_0} = -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i) = 0 \\ \frac{\partial S}{\partial \theta_1} = -2 \sum_{i=1}^n X_i (Y_i - \beta_0 - \beta_1 X_i) = 0 \end{cases} \Rightarrow \begin{cases} \sum_{i=1}^n Y_i = n \beta_0 + \beta_1 \sum_{i=1}^n X_i \\ \sum_{i=1}^n X_i Y_i = \beta_0 \sum_{i=1}^n X_i + \beta_1 \sum_{i=1}^n X_i^2 \end{cases}$$

Замечание. Именно эта линейная система удобна для определения значений параметров по элементам выборки

Решая систему, получим

$$\bar{\theta}_1 = \frac{n \sum_{i=1}^n X_i Y_i - \sum_{i=1}^n Y_i \cdot \sum_{i=1}^n X_i}{n \sum_{i=1}^n X_i^2 - \left(\sum_{i=1}^n X_i \right)^2}$$

Упростим выражение, используя известные формулы

$$\bar{\theta}_1 = \frac{\frac{1}{n} \sum_{i=1}^n X_i Y_i - \frac{1}{n} \sum_{i=1}^n Y_i \cdot \frac{1}{n} \sum_{i=1}^n X_i}{\frac{1}{n} \sum_{i=1}^n X_i^2 - \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2} = \frac{\frac{1}{n} \sum_{i=1}^n X_i Y_i - \bar{Y} \cdot \bar{X}}{\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$n\theta_0 = \sum_{i=1}^n Y_i - \theta_1 \sum_{i=1}^n X_i \Rightarrow \theta_0 = \frac{1}{n} \sum_{i=1}^n Y_i - \theta_1 \frac{1}{n} \sum_{i=1}^n X_i \Rightarrow \bar{\theta}_0 = \bar{Y} - \bar{\theta}_1 \bar{X}$$

Замечание. Полученную формулу для $\bar{\theta}_1$ в рассмотренном ранее примере можно интуитивно интерпретировать следующим образом

$$\bar{\theta}_1 = \frac{\text{как вместе меняются цена и площадь}}{\text{как меняется площадь}}$$


Замечание. В формуле для $\bar{\theta}_1$ в числителе стоит ковариация, а в знаменателе дисперсия с точностью до множителей

Иллюстрация 3

Истинные параметры (те, которые использовали при генерации точек): $\theta_0 = 2.0000$, $\theta_1 = 0.0800$

Оценки МНК: $\theta_0 = 2.1842$, $\theta_1 = 0.0774$

Разница (смещение): $\Delta\theta_0 = 0.1842$, $\Delta\theta_1 = -0.0026$



СВОЙСТВА ОЦЕНОК МНК

Оценки – случайные величины (зависят от выборки)
Поэтому возникают естественные вопросы

- «Попадает» ли оценка в среднем в истинное значение? (несмещенность)
- Насколько сильно оценки «разбросаны»? (эффективность)
- Улучшаются ли оценки с ростом выборки? (состоятельность)

Рассмотрим доказательства свойств для простой линейной регрессии $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$

Теорема. При выполнении предположений (1) – (4) оценки МНК для простой линейной регрессии $Y = \bar{\theta}_0 + \bar{\theta}_1 X$

$$\bar{\theta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}, \bar{\theta}_0 = \bar{Y} - \bar{\theta}_1 \bar{X} \text{ являются несмещенными}$$

Доказательство:

$$\bar{\theta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})Y_i - \bar{Y} \sum_{i=1}^n (X_i - \bar{X})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Поскольку $\sum_{i=1}^n (X_i - \bar{X}) = 0$ имеем $\bar{\theta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})Y_i}{\sum_{i=1}^n (X_i - \bar{X})^2}$

Обозначим $\sum_{i=1}^n (X_i - \bar{X})^2 = S_{xx}$, $\frac{X_i - \bar{X}}{S_{xx}} = w_i$. Тогда

$$\bar{\theta}_1 = \sum_{i=1}^n w_i Y_i$$

Подставим истинную модель

$$\bar{\theta}_1 = \sum_{i=1}^n w_i (\theta_0 + \theta_1 X_i + \varepsilon_i) = \theta_0 \sum_{i=1}^n w_i + \theta_1 \sum_{i=1}^n w_i X_i + \sum_{i=1}^n w_i \varepsilon_i$$

Вычислим $\sum_{i=1}^n w_i = \sum_{i=1}^n \frac{X_i - \bar{X}}{S_{xx}} = \frac{1}{S_{xx}} \sum_{i=1}^n (X_i - \bar{X}) = 0$ и

$$\sum_{i=1}^n w_i X_i = \sum_{i=1}^n \frac{X_i - \bar{X}}{S_{xx}} X_i = \frac{1}{S_{xx}} \sum_{i=1}^n (X_i - \bar{X}) X_i$$

При этом

$$\sum_{i=1}^n (X_i - \bar{X}) X_i = \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X} + \bar{X}) =$$

$$= \sum_{i=1}^n (X_i - \bar{X})^2 + \bar{X} \sum_{i=1}^n (X_i - \bar{X}) = S_{xx}$$

Т. е. $\sum_{i=1}^n w_i X_i = \frac{S_{xx}}{S_{xx}} = 1$

Тогда $\bar{\theta}_1 = \theta_0 \cdot 0 + \theta_1 \cdot 1 + \sum_{i=1}^n w_i \varepsilon_i = \theta_1 + \sum_{i=1}^n w_i \varepsilon_i$

$$E \bar{\theta}_1 = \theta_1 + \sum_{i=1}^n w_i E \varepsilon_i = \theta_1$$

$$\bar{\theta}_0 = \bar{Y} - \bar{\theta}_1 \bar{X} \Rightarrow E \bar{\theta}_0 = E \bar{Y} - \bar{X} E \bar{\theta}_1$$

Поскольку $E \bar{Y} = \theta_0 + \theta_1 \bar{X}$, то $E \bar{\theta}_0 = E \bar{Y} - \bar{X} E \bar{\theta}_1 = \theta_0 + \theta_1 \bar{X} - \bar{X} \theta_1 = \theta_0$

Иллюстрация 4

Истинный $\theta_0 = 2.0$

Среднее оценок $\bar{\theta}_0 = 2.0050$

Смещение = 0.0050


Стандартная ошибка = 0.1469

Истинный $\theta_1 = 0.080$

Среднее оценок $\bar{\theta}_1 = 0.0799$

Смещение = -0.0001

Стандартная ошибка = 0.0019



Вывод: Среднее оценок близко к истинным значениям $\rightarrow$ оценка несмещенная

Теорема. При выполнении предположений (1) – (4) дисперсии оценок вычисляются по формулам

$$D(\bar{\theta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}, \quad D(\bar{\theta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$$

Доказательство:

Воспользуемся выражением из предыдущей теоремы $\bar{\theta}_1 = \theta_1 + \sum_{i=1}^n w_i \varepsilon_i$.

$$D(\bar{\theta}_1) = 0. \text{ Поэтому } D \bar{\theta}_1 = D \sum_{i=1}^n w_i \varepsilon_i$$

$$\text{Поскольку ошибки } \varepsilon_i \text{ некоррелированные, } D \bar{\theta}_1 = \sum_{i=1}^n w_i^2 D \varepsilon_i = \sigma^2 \sum_{i=1}^n w_i^2.$$

$$\text{Вычислим } \sum_{i=1}^n w_i^2 = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{S_{xx}} \right)^2 = \frac{1}{S_{xx}^2} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{S_{xx}}{S_{xx}^2} = \frac{1}{S_{xx}}$$

$$\text{Окончательно имеем } D(\bar{\theta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Формула $D(\bar{\theta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$ выводится аналогично

Теорема. (Гаусса-Маркова) При выполнении предположений (1) – (4) оценка МНК $\bar{\theta}_1$ имеет наименьшую дисперсию среди всех линейных

несмещенных оценок $\hat{\theta}_1 = \sum_{i=1}^n c_i Y_i$

Доказательство:

Условие несмещенности оценки $\hat{\theta}_1 = \sum_{i=1}^n c_i E Y_i = \sum_{i=1}^n c_i (\theta_0 + \theta_1 X_i) = \theta_1$

должно выполняться при любых θ_0, θ_1 . Тогда $\sum_{i=1}^n c_i = 0, \sum_{i=1}^n c_i X_i = 1$

Запишем $c_i = w_i + d_i, w_i = \frac{X_i - \bar{X}}{S_{xx}}$. Из условия на c_i и

$\sum_{i=1}^n w_i = 0, \sum_{i=1}^n w_i X_i = 1$ следует, что $\sum_{i=1}^n d_i = 0, \sum_{i=1}^n d_i X_i = 0$

Дисперсия произвольной оценки

$$D\hat{\theta}_1 = \sum_{i=1}^n c_i^2 D Y_i = \sigma^2 \sum_{i=1}^n (w_i + d_i)^2 = \sigma^2 \left(\sum_{i=1}^n w_i^2 + 2 \sum_{i=1}^n w_i d_i + \sum_{i=1}^n d_i^2 \right)$$

Рассмотрим $\sum_{i=1}^n w_i d_i = \sum_{i=1}^n \frac{X_i - \bar{X}}{S_{xx}} d_i = \frac{1}{S_{xx}} \left(\sum_{i=1}^n X_i d_i - \bar{X} \sum_{i=1}^n d_i \right) = 0$

Окончательно $D\hat{\theta}_1 = \sigma^2 \sum_{i=1}^n w_i^2 + \sigma^2 \sum_{i=1}^n d_i^2 = D\bar{\theta}_1 + \sigma^2 \sum_{i=1}^n d_i^2$

Т. е. $D\hat{\theta}_1 \geq D\bar{\theta}_1$

Теорема. При выполнении предположений (1) – (4) и условия

$\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \rightarrow Q > 0$ оценка МНК $\bar{\theta}_1$ состоятельная, т. е. $\bar{\theta}_1 \xrightarrow[n \rightarrow \infty]{P} \theta_1$

Доказательство:

Из доказательства несмещенности имеем $\bar{\theta}_1 = \theta_1 + \sum_{i=1}^n w_i \varepsilon_i$

А дисперсия $D\bar{\theta}_1 = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sigma^2}{n \cdot \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sigma^2}{n D\bar{X}} \xrightarrow[n \rightarrow \infty]{} 0$

Так как оценка несмещенная и её дисперсия стремится к 0, оценка сходится по вероятности к истинному значению (состоятельная) $\bar{\theta}_1 \xrightarrow[n \rightarrow \infty]{P} \theta_1$

КОЭФФИЦИЕНТ ДЕТЕРМИНАЦИИ

Когда модель построена, возникает вопрос: насколько хорошо наша модель объясняет данные?

Попробуем ответить на этот вопрос

Введем обозначения:

Как и ранее Y_i – фактическое наблюдаемое значение (в примере реальная цена квартиры). $\hat{Y}_i$ – расчетное (предсказанное моделью) значение $\hat{Y}_i = \theta_0 + \theta_1 X_i$. $\bar{Y}$ – среднее значение (средняя цена по квартирам в выборке)

Рассмотрим следующие суммы:

$SST = \sum_{i=1}^n (Y_i - \bar{Y})^2$ измеряет насколько цены отличаются от средней

$SSR = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$ измеряет насколько прогнозы отличаются от средней

$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$ измеряет насколько факты отличаются от прогнозов

Несложно показать, что $SST = SSR + SSE$

$Y_i - \bar{Y} = (Y_i - \hat{Y}_i) + (\hat{Y}_i - \bar{Y})$. Возводим в квадрат и суммируем

$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + 2 \sum_{i=1}^n (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y})$. Последняя

сумма равна 0

Определение. Будем называть коэффициентом детерминации величину

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

Свойства:

- $0 \leq R^2 \leq 1$
- Показывает долю дисперсии Y , объясненную моделью

О чем говорит коэффициент:

0.0	Модель бесполезна: площадь не помогает предсказать цену
0.3–0.5	Умеренная связь: площадь важна, но есть другие факторы
0.7–0.9	Сильная связь: модель хорошо описывает данные
1.0	Идеальное совпадение (все точки на прямой)

Иллюстрация 5

SST (общая) = 445.8198


SSR (объясненная) = 425.6552

SSE (остаточная) = 20.1646

$R^2 = 0.9548$

Интерпретация: 95.5% изменчивости Y объяснено моделью

Коэффициент детерминации R^2



БАЙЕСОВСКИЙ ПОДХОД

Обсудим другой подход к построению регрессии

В предыдущих рассуждениях мы использовали частотный подход (классический), предполагая, что:

- Параметры θ — фиксированные неизвестные константы
- А данные Y — случайные (зависят от выборки)

- Тогда возникал вопрос: если повторить эксперимент много раз, как будут вести себя оценки?

Но можно использовать байесовский подход, считая, что:

- Параметры θ — случайные величины (есть неопределённость)
- А данные Y — фиксированные (мы их уже наблюдали)
- Вопрос меняется: что мы можем сказать о параметрах с учётом наблюдаемых данных?

Первый подход начинается от параметра и задается вопросом о вероятности данных, а второй идет от данных и интересуется вероятностью параметра. На нашем примере это будет выглядеть так

Пример

(1) Частотный подход: если истинная средняя цена квартиры 75 м² равна 6 млн руб., какова вероятность увидеть в выборке среднюю цену 6.3 млн руб.?

(2) Байесовский подход: увидев в выборке среднюю цену 6.3 млн руб. для квартир 75 м², какова вероятность, что истинная средняя цена равна 6 млн руб.?

Схема байесовского вывода:

1. Априорное распределение $P(\theta)$ — наше знание о параметрах до получения данных
2. Правдоподобие $P(Y|X, \theta)$ — вероятность данных при заданных параметрах
3. Апостериорное распределение $P(\theta|Y, X)$ — обновленное знание после получения данных

Сформулируем теорему, на которую опирается такой подход

Теорема. (байесовское обновление) Пусть $P(\theta)$ априорное распределение до получения данных, а $P(Y|X, \theta)$ вероятность данных при заданных параметрах. Тогда апостериорное распределение после получения данных равна

$$P(\theta|Y, X) = \frac{P(Y|X, \theta) \cdot P(\theta)}{P(Y|X)}, \text{ где } P(Y|X) \text{ нормировочная константа}$$

БАЙЕСОВСКАЯ ПРОСТАЯ ЛИНЕЙНАЯ РЕГРЕССИЯ

Рассмотрим простую линейную модель $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \varepsilon_i \sim N_{0, \sigma^2}$

Будем предполагать независимые нормальные априорные распределения $\theta_0 \sim N_{\mu_0^{(0)}, \sigma_0^2}, \theta_1 \sim N_{\mu_0^{(1)}, \sigma_1^2}$

Теорема. При указанных предположениях апостериорное распределение параметров нормально $\theta_1 | Y, X \sim N_{\bar{\mu}^{(1)}, \bar{\sigma}_1^2}$, где

- выборочное (апостериорные) матожидание

$$\bar{\mu}^{(1)} = \bar{\sigma}_1^2 \left(\frac{\mu_0^{(1)}}{\sigma_1^2} + \frac{S_{xy}}{\sigma^2} \right), S_{xy} = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$

- точность (обратная дисперсия)

$$\frac{1}{\bar{\sigma}_1^2} = \frac{1}{\sigma_1^2} + \frac{S_{xx}}{\sigma^2}, S_{xx} = \sum_{i=1}^n (X_i - \bar{X})^2$$

КАК ОЦЕНИТЬ ПАРАМЕТРЫ ПРИ БАЙЕСОВСКОМ ПОДХОДЕ

В отличие от частотного подхода (где мы получаем одну точку – оценку МНК), в байесовском подходе мы получаем полное распределение параметра $\theta_1 | Y, X \sim N_{\bar{\mu}^{(1)}, \bar{\sigma}_1^2}$. Но на практике нам часто нужна конкретная цифра. Вот как её находят

- (1) Точечные оценки из апостериорного распределения

- Апостериорное среднее $E(\theta | Y, X) = \bar{\mu}^{(1)}$. Наиболее распространённый выбор, минимизирует среднеквадратичную ошибку
- Апостериорная мода. Когда нужно наиболее вероятное значение, при асимметричных распределениях
- Апостериорная медиана. При наличии выбросов

- (2) Интервальная оценка (кредитный интервал)

$P(a \leq \theta \leq b | Y, X) = 0.95$. Для нормального распределения

$\bar{\mu}^{(1)} \pm 1.96 \cdot \bar{\sigma}_1$. В общем случае взять 2.5-й и 97.5-й квантили апостериорного распределения

Пример

До данных (априори):

- Эксперт говорит: цена за м² около 80 тыс. руб., но я не уверен: от 60 до 100
- $\mu_0^{(1)} = 0.08$ млн.руб/м², $\sigma_1^2 = 0.02^2$

Данные:

- Выборка из 50 квартир дает МНК-оценку $\bar{\theta}_1 = 0.075$

После данных (апостериори):

- $\bar{\mu}^{(1)} = 0.077$ (компромисс: 0.077 между 0.08 и 0.075)
- $\bar{\sigma}_1^2 = 0.008$ (неопределенность уменьшилась)

Замечание. Когда использовать байесовский подход?

Да, если:

- Мало данных, но есть экспертное мнение
- Нужна полная картина неопределённости (распределение, а не только точка)
- Принимаете решения с риском (нужны вероятности)
- Сложная модель (иерархическая, с пропусками)

Нет, если:

- Данных много (априори «забудется»), результаты совпадут с МНК)
- Нужен быстрый ответ
- Нет обоснованного априорного мнения
- Простая интерпретация важнее точности

Иллюстрация 6

График визуализирует процесс байесовского обновления знаний о параметре θ_1 (цене за квадратный метр). Он показывает, как менялось наше представление о параметре: от первоначального предположения до итоговой оценки после анализа данных

Истинное значение: $\theta_1 = 0.0800$

Априорное распределение: $\theta_1 \sim N(0.050, 0.0316)$

Оценка МНК: $\bar{\theta}_1 = 0.0774$

Байесовская оценка: $\bar{\theta}_1 = 0.0773 \pm 0.00187$

Что мы видим на графике

Зелёная пунктирная кривая – априорное распределение. Отражает наше мнение до сбора данных (например, экспертную оценку). Она широкая и пологая, что означает высокую

неопределённость: мы допускаем, что цена за m^2 может быть разной, но в среднем ожидаем около 0.05

Красная сплошная кривая – апостериорное распределение. Отражает обновлённое мнение *после* учёта выборки. Кривая стала уже и выше, что означает уменьшение неопределённости. Она сместилась вправо, потому что данные "потянули" оценку в сторону реальных значений


Вертикальные линии (точечные оценки):

Зелёная пунктирная – среднее априорного распределения – 0,05 экспертное мнение

Синяя штрихпунктирная – оценка МНК (по данным) – 0,075 чистая статистик

Красная сплошная – среднее апостериорного распределения – 0,077 итоговая байесовская оценка

Чёрная сплошная – истинное значение параметра – 0,08 известно только в учебном примере



Ключевые выводы из графика:

1. Компромисс: апостериорная оценка (красная линия) находится между априорным мнением и оценкой МНК. Байесовский подход не отвергает ни эксперта, ни данные, а взвешивает их

2. Рост уверенности: апостериорная кривая уже априорной $\rightarrow$ после получения данных разброс возможных значений θ_1 сократился
3. Сдвиг к истине: несмотря на то, что априор был смещён (0.05), данные "исправили" оценку, приблизив её к истинному значению (0.08)

Байесовский подход – это математически строгий способ обновлять убеждения по мере поступления новой информации