

ЛЕКЦИЯ 12

ОЦЕНКА ДИСПЕРСИИ ОШИБОК

На прошлой лекции мы получили оценки $\bar{\theta}_0, \bar{\theta}_1$, но для статистических выводов нам нужно знать дисперсию ошибок $\sigma^2 = D(\varepsilon_i)$. Поэтому ее нам придется оценивать по данным

Определение. Остаток e_i это разность между фактическим и прогнозным значением $e_i = Y_i - \hat{Y}_i = Y_i - (\bar{\theta}_0 + \bar{\theta}_1 X_i)$

Замечание. Остаток показывает, насколько модель ошиблась для i -го наблюдения

Теорема. Несмещенная оценка дисперсии σ^2 имеет вид

$$s^2 = \frac{SSE}{n-2} = \frac{\sum_{i=1}^n e_i^2}{n-2}, \text{ где } n-2 \text{ число степеней свободы}$$

Комментарии:

$$\text{Рассмотрим } SSE = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_{ii})^2$$

Заметим, что остатки зависят от $\bar{\theta}_0, \bar{\theta}_1$, которые сами вычисляются по тем же данным. При вычислении оценок МНК мы «потратили» 2 степени свободы (оценили два параметра). Можно показать (полное доказательство требует матричной алгебры), что $E(SSE) = (n-2)\sigma^2$

Это означает, что $E\left(\frac{SSE}{n-2}\right) = \sigma^2$. Что означает несмещенность оценки

s^2

Иллюстрация 1

Истинное $\sigma = 0.5000$

$SSE = 20.1646$

Оценка $s^2 = SSE/(n-2) = 20.1646/98 = 0.2058$

Оценка $s = \sqrt{s^2} = 0.4536$

Относительная ошибка: -9.28%




График визуализирует остатки регрессии $e_i = Y_i - \hat{Y}_i$ – разности между реальными ценами квартир и ценами, которые предсказала наша прямая МНК. Мы видим, что успешно оценили уровень случайного шума s и что остатки ведут себя «правильно», что позволяет доверять дальнейшим статистическим выводам. Точки разбросаны хаотично вокруг нуля, без явных трендов или «воронков». Это подтверждает, что модель уловила всю систематическую часть, а в остатках остался только случайный шум

ВЫБОРОЧНЫЕ РАСПРЕДЕЛЕНИЯ ОЦЕНОК

Теорема. При выполнении предположений (1)–(5) (включена нормальность ошибок) оценки параметра имеют законы распределения

$$\bar{\theta}_1 \sim N_{\theta_1, \frac{\sigma^2}{S_{xx}}}, \bar{\theta}_0 \sim N_{\theta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}} \right)}, \text{ где } S_{xx} = \sum_{i=1}^n (X_i - \bar{X})^2$$

Доказательство:

В прошлой лекции было показано, что $\bar{\theta}_1 = \theta_1 + \sum_{i=1}^n w_i \varepsilon_i, w_i = \frac{X_i - \bar{X}}{S_{xx}}$, а

$$\bar{\theta}_0 = \bar{Y} - \bar{\theta}_1 \bar{X}$$

Кроме того, получены дисперсии оценок $D(\bar{\theta}_1) = \frac{\sigma^2}{S_{xx}}$,

$$D(\bar{\theta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}} \right), \text{ где } S_{xx} = \sum_{i=1}^n (X_i - \bar{X})^2 \text{ соответственно}$$

По предположению (5) $\varepsilon_i \sim N_{0, \sigma^2}$

Линейная комбинация независимых нормальных величин также нормальна, поэтому для $\bar{\theta}_1 = \theta_1 + \sum_{i=1}^n w_i \varepsilon_i$ имеем $\bar{\theta}_1 \sim N_{\theta_1, \frac{\sigma^2}{S_{xx}}}$

Для $\bar{\theta}_0 = \bar{Y} - \bar{\theta}_1 \bar{X} = (\theta_0 + \theta_1 \bar{X} + \bar{\varepsilon}) - \bar{\theta}_1 \bar{X} = \theta_0 + \bar{\varepsilon} - (\bar{\theta}_1 - \theta_1) \bar{X}$, $\bar{\varepsilon} = \frac{1}{n} \sum_{i=1}^n \varepsilon_i$

Нормальность также опирается на нормальность ε_i . Т. о. $\bar{\theta}_0 \sim N_{\theta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}} \right)}$

Отметим, что в формулах дисперсий присутствует неизвестный параметр σ^2 . Попробуем заменить его на его оценку s^2

Теорема. При замене σ на его оценку s статистики $t_1 = \sqrt{S_{xx}} \frac{\bar{\theta}_1 - \theta_1}{s} \sim T_{n-2}$, $t_0 = \frac{\bar{\theta}_0 - \theta_0}{s \sqrt{\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}}}} \sim T_{n-2}$ имеют распределения Стъ-

юдента с $n - 2$ степенями свободы

Доказательство:

Выше доказано, что $\bar{\theta}_1 \sim N_{\theta_1, \frac{\sigma^2}{S_{xx}}}$. Поэтому $\sqrt{S_{xx}} \frac{\bar{\theta}_1 - \theta_1}{\sigma} \sim N_{0,1}$

Из формулы $s^2 = \frac{\sum_{i=1}^n e_i^2}{n-2}$ имеем $(n-2)s^2 = \sum_{i=1}^n e_i^2$. И как сумма квадратов

нормально распределенных величин распределена как хи-квадрат. А

именно $\frac{(n-2)s^2}{\sigma^2} \sim \chi_{n-2}^2$

При этом частное от деления независимых нормального и корня из хи-квадрат распределения дают распределение Стъюдента

$$Z \sim N_{0,1}, V \sim \chi_v^2 \Rightarrow \frac{Z}{\sqrt{\frac{V}{v}}} \sim T_v$$

$$\text{Т. о. имеем } \frac{\sqrt{S_{xx}} \frac{\bar{\theta}_1 - \theta_1}{\sigma}}{\sqrt{\frac{(n-2)s^2}{\sigma^2(n-2)}}} = \sqrt{S_{xx}} \frac{\bar{\theta}_1 - \theta_1}{s} \sim T_{n-2}$$

Для t_0 доказывается аналогично


Иллюстрация 2

Истинный $\theta_1 = 0.0800$

Среднее оценок $\bar{\theta}_1 = 0.0800$

Теоретическая std. ошибка = 0.0028

Средняя оценённая std. ошибка = 0.0027



По 2000 виртуальным экспериментам смотрим, совпадают ли реальные данные с полученными формулами

1. Гистограмма: реальные значения наклона $\bar{\theta}_1$, полученные из 2000 выборок
2. Красная кривая: это теоретическое нормальное распределение, заданное формулой в теореме
3. Вертикальные линии: красная – истинное значение параметра; зелёная – среднее значение для 2000 оценок

Это иллюстрирует нормальность и несмещенность оценки

На втором графике аналогично представлена статистика t_1

ДОВЕРИТЕЛЬНЫЕ ИНТЕРВАЛЫ

Теорема. Доверительный интервал с уровнем доверия $1 - \alpha$ для параметра θ_1 имеет вид

$$\left(\bar{\theta}_1 - t_{1-\frac{\alpha}{2}, n-2} \frac{s}{\sqrt{S_{xx}}}; \bar{\theta}_1 + t_{1-\frac{\alpha}{2}, n-2} \frac{s}{\sqrt{S_{xx}}} \right), \text{ а для параметра}$$

$$\theta_0 \text{ соответственно } \left(\bar{\theta}_0 - t_{1-\frac{\alpha}{2}, n-2} s \sqrt{\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}}}; \bar{\theta}_0 + t_{1-\frac{\alpha}{2}, n-2} s \sqrt{\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}}} \right)$$

Доказательство:

$$\text{Из предыдущей теоремы } P\left(-t_{1-\frac{\alpha}{2}, n-2} \leq \sqrt{S_{xx}} \frac{\bar{\theta}_1 - \theta_1}{s} \leq t_{1-\frac{\alpha}{2}, n-2}\right) = 1 - \alpha$$

После преобразований получим требуемое

Второе аналогично

Иллюстрация 3

ДОВЕРИТЕЛЬНЫЕ ИНТЕРВАЛЫ (95%)

Критическое значение $t(48) = 2.011$

θ_1 :

Оценка: $\theta_1 = 0.0788$

Стд. ошибка: 0.00254

95% ДИ: [0.0736, 0.0839]

Истинное значение 0.0800 попадает в интервал

θ_0 :



Оценка: $\theta_0 = 2.0856$

Стд. ошибка: 0.1900

95% ДИ: [1.7035, 2.4677]

Истинное значение 2.0000 попадает в интервал

95% доверительные интервалы ($t_{\text{crit}} = 2.011$)



Из 50 доверительных интервалов 49 (98%) накрыли истинное значение. Ожидалось около 95% (48 из 50).

ПРОВЕРКА ГИПОТЕЗ

Постановка задачи: проверить, существует ли статистически значимая линейная связь между X и Y

Гипотезы $H_0 : \theta_1 = 0$ (связи нет, в примере площадь не влияет на цену),

$H_1 : \theta_1 \neq 0$ (связь есть)

Статистика $\sqrt{S_{xx}} \frac{\bar{\theta}_1}{s}$ при справедливой гипотезе H_0 имеет распределение

Стьюдента с $n - 2$ степенями свободы. Поэтому правило принятия

решения следующее: если $t_{\text{набл}} = \sqrt{S_{xx}} \frac{\bar{\theta}_1}{s}, |t| > t_{1-\frac{\alpha}{2}, n-2}$, то гипотеза отвер-

гается. Иначе, принимается

Иллюстрация 4

СЛУЧАЙ 1: сильная связь

Истинный наклон: 0.08


Оценка t : 30.424 ($|t| > 2.011 \rightarrow$ Отвергаем H_0)

СЛУЧАЙ 2: нет связи

Истинный наклон: 0.00

Оценка t : 0.444 ($|t| < 2.011 \rightarrow$ Не отвергаем H_0)

Сравнение: Отвергаем vs Не отвергаем H_0 (Крит. знач. = ± 2.01)



Сравнение двух графиков показывает суть статистического теста. На обоих графиках изображено одно и то же теоретическое распределение – t -распределение Стьюдента (синяя кривая), но результаты эксперимента – реальная t -статистика (зеленая линия) различаются. Красные хвосты – это области отвержения (критические области). Туда попадают значения, которые крайне маловероятны при отсутствии связи (вероятность менее 5%). Если наша статистика попала сюда, мы делаем вывод: «Это не могло быть случайностью»

ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ ДЛЯ СРЕДНЕГО

Этот доверительный интервал уже не для параметров, а для самой функции регрессии. В нашем примере для средней цены квартиры фиксированной площади

Теорема. Доверительный интервал с уровнем доверия $1 - \alpha$ для функции $E(Y|X_0)$, имеет вид

$$\left(\hat{Y}_0 - t_{1-\frac{\alpha}{2}, n-2} s \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{S_{xx}}}; \hat{Y}_0 + t_{1-\frac{\alpha}{2}, n-2} s \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{S_{xx}}} \right),$$

где $\hat{Y}_0 = \bar{\theta}_0 + \bar{\theta}_1 X_0$ – прогноз для X_0

Доказательство:

Оценка среднего для фиксированного значения X_0 ищется по формуле

$$\hat{Y}_0 = \bar{\theta}_0 + \bar{\theta}_1 X_0$$

Дисперсия для него

$$D\hat{Y}_0 = D(\bar{\theta}_0 + \bar{\theta}_1 X_0) = D\bar{\theta}_0 + X_0^2 D\bar{\theta}_1 + 2X_0 \text{cov}(\bar{\theta}_0, \bar{\theta}_1)$$

Не останавливаясь на доказательстве, запишем, что

$$D\hat{Y}_0 = \sigma^2 \left(\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{S_{xx}} \right)$$

Заменяя σ на его оценку s , получим $\frac{\hat{Y}_0 - E(Y|X_0)}{s \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{S_{xx}}}} \sim T_{n-2}$

НЕЛИНЕЙНЫЕ ПРЕОБРАЗОВАНИЯ ПЕРЕМЕННОЙ В ЛИНЕЙНОЙ МОДЕЛИ

Линейная регрессия называется линейной потому, что она линейна по параметрам θ_i , а не обязательно по переменной X

Мы можем преобразовывать X любым способом, создавая новые переменные, и модель останется линейной

$Y_i = \theta_1 \varphi_1(X_i) + \theta_2 \varphi_2(X_i) + \dots + \theta_m \varphi_m(X_i)$, где $\varphi_i(X)$ – любые функции от исходного X

Примеры

Полиномиальная $Y = \theta_0 + \theta_1 X + \theta_2 X^2 + \theta_3 X^3$

Логарифмическая $Y = \theta_0 + \theta_1 \ln X$

Экспоненциальная (линеаризованная) $\ln Y = \theta_0 + \theta_1 X$

Тригонометрическая $Y = \theta_0 + \theta_1 \sin X + \theta_2 \cos X$

Обратная $Y = \theta_0 + \theta_1 \frac{1}{X}$

Статистические выводы полученные ранее остаются прежними и для такого рода моделей. Используются

1. Оценки МНК: минимизируем $SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$
2. Степени свободы: $n - m$, где m – число оцениваемых параметров
3. Доверительные интервалы: $\bar{\theta}_i \pm t_{1-\frac{\alpha}{2}, n-m} \cdot \sqrt{\hat{D}(\bar{\theta}_i)}$

4. Проверка гипотезы: $H_0: \theta_i = 0$, $H_1: \theta_i \neq 0$, $t_{\text{набл}} = \frac{\bar{\theta}_i}{\sqrt{\hat{D}(\bar{\theta}_i)}} \sim T_{n-m}$

При этом выбор вида зависимостей часто диктуется предметной областью. Очень хорошо «работает» полиномиальная зависимость. Здесь правда возникает вопрос выбора степени полинома: слишком низкая степень (например, линейная) → не уловим сложную зависимость (большое смещение), слишком высокая степень → усложнение, модель будет «ловить шум»

В таком случае можно строить и проверять зависимости разных степеней, сравнивать их величине SSE , проверять гипотезу о значимости коэффициента

Такого рода задачи встречаются в различных предметных областях:

- Физика. Зависимость электрического сопротивления проводника от температуры $R = \theta_0 + \theta_1 T + \theta_2 T^2$. Квадратичный член учитывает нелинейность при высоких температурах
- Экономика. Снижение себестоимости продукции по мере накопления опыта производства. $\ln C = \theta_0 + \theta_1 \ln Q$
- Инженерия. Описание формы оптического зеркала или линзы. $z = \theta_0 + \theta_1 r^2 + \theta_2 r^4 + \theta_3 r^6$
- Химия. Зависимость скорости реакции от температуры.

$$\ln k = \theta_0 + \theta_1 \cdot \frac{1}{T}$$

Иллюстрация 5

На всех 4 примерах видно, что простая прямая систематически ошибается (в начале точек она слишком высоко/низко, в конце — наоборот), тогда как нелинейная кривая точно описывает тренд

