

Федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский университет ИТМО»

Системы искусственного интеллекта

Лабораторная работа №2

Логистическая регрессия

Классификация объектов набора Pima Indians Diabetes

Выполнил:

Чэнь Хаолинъ Р3316 407960

Преподаватель:

Болдырева Елена Александровна

г. Санкт-Петербург, 2026

Содержание

1	Введение	2
2	Описание метода	2
2.1	Линейная и логистическая регрессия	2
2.2	Гипотеза, потери и решение	2
2.3	Методы оптимизации	3
2.4	Метрики	3
3	Псевдокод метода	3
3.1	Обучение модели	3
3.2	План эксперимента	4
4	Результаты выполнения	4
4.1	Данные и предварительная обработка	4
4.2	Описательная статистика и визуализация	5
4.3	Разбиение и сетка гиперпараметров	6
4.4	Метрики каждой комбинации	7
4.5	Влияние гиперпараметров и сходимость	8
4.6	Выбранная модель и интерпретация	9
4.7	Проверка реализации	9
5	Примеры использования метода	10
5.1	Прогнозы на отложенных объектах	10
5.2	Ситуации применения	10
6	Сравнение методов	10
6.1	Сравнительный анализ	10
6.2	Примеры лучшего использования	11
7	Заключение	11

1. Введение

В лабораторной работе требуется выбрать один из предложенных наборов данных для бинарной классификации, выполнить предварительную обработку, построить графики описательной статистики и разделить наблюдения на обучающую и тестовую выборки. Логистическую регрессию необходимо реализовать без готовых алгоритмов машинного обучения: вычислять сигмоиду и логарифмическую функцию потерь, обучать модель градиентным спуском и изменять шаг и число итераций. Дополнительно исследуется метод оптимизации. Каждая конфигурация оценивается по Accuracy, Precision, Recall и F1, после чего анализируется влияние гиперпараметров.

Цель работы — выполнить эти этапы на наборе Pima Indians Diabetes и сравнить градиентный спуск с методом Ньютона. Целевой признак Outcome принимает значения 0 и 1; положительным считается класс 1.

Реализованы устойчивое вычисление сигмиды и log loss, полный градиентный спуск, метод Ньютона, предобработка и четыре метрики. Рассмотрена 21 комбинация гиперпараметров. Выбранная по validation log loss модель GD с $\alpha = 0.1$, $T = 100$ после переобучения на train дала на test Accuracy 0.7792, Precision 0.7381, Recall 0.5741 и F1 0.6458.

2. Описание метода

2.1. Линейная и логистическая регрессия

Обе модели строят линейный предиктор $z_i = \tilde{x}_i^\top w$, где первый элемент $\tilde{x}_i$ равен 1. В линейной регрессии он непосредственно задаёт прогноз количественного отклика. В логистической регрессии он определяет логарифм шансов бинарного события:

$$\log \frac{p_i}{1 - p_i} = \tilde{x}_i^\top w, \quad p_i = P(y_i = 1 \mid x_i).$$

Для оценки коэффициентов линейной регрессии часто используют формулу МНК $(X^\top X)^{-1} X^\top y$. В логистической модели параметры находятся численной минимизацией отрицательного логарифма правдоподобия Бернулли. Нормальность и постоянная дисперсия ошибок линейной регрессии не распространяются на бинарный отклик, для которого $\text{Var}(y_i \mid x_i) = p_i(1 - p_i)$.

2.2. Гипотеза, потери и решение

Вероятность вычисляется сигмидой:

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \begin{cases} (1 + e^{-z})^{-1}, & z \geq 0, \\ e^z / (1 + e^z), & z < 0. \end{cases}$$

Разделение ветвей исключает переполнение экспоненты для больших по модулю логитов. Решение принимается при фиксированном пороге 0.5: $\hat{y}_i = \mathbf{1}[p_i \geq 0.5]$.

$$\begin{aligned} L(w) &= -\frac{1}{n} \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)] \\ &= \frac{1}{n} \sum_{i=1}^n [\log(1 + e^{z_i}) - y_i z_i]. \end{aligned}$$

В коде $\log(1 + e^z)$ вычисляется через `np.logaddexp(0, z)`, поэтому не требуется искусственно обрезать вероятности перед логарифмированием. Регуляризация в целевую функцию не добавлена.

2.3. Методы оптимизации

Для матрицы X , включающей столбец единиц, градиент и гессиан имеют вид

$$g = \frac{1}{n} X^T (p - y), \quad H = \frac{1}{n} X^T D X, \quad D_{ii} = p_i(1 - p_i).$$

Полный градиентный спуск обновляет все параметры по всей обучающей выборке:

$$w^{(t+1)} = w^{(t)} - \alpha g^{(t)}.$$

Метод Ньютона учитывает кривизну функции потерь:

$$(H^{(t)} + 10^{-8} I) d^{(t)} = g^{(t)}, \quad w^{(t+1)} = w^{(t)} - \alpha d^{(t)}.$$

Система решается `np.linalg.solve`; обратная матрица явно не строится. Добавка $10^{-8} I$ стабилизирует линейную систему и не является штрафом в $L(w)$. Для Ньютона α — множитель шага: $\alpha = 1$ соответствует полному шагу, меньшие значения — демпфированию. Обе реализации начинают с $w = 0$ и выполняют ровно T итераций. Автоматической ранней остановки и поиска длины шага нет.

При d признаках одна итерация GD требует порядка $O(nd)$ операций, а Ньютона — $O(nd^2 + d^3)$. Для восьми признаков решение системы 9×9 невелико; при большом d преимущество по числу итераций не означает преимущество по времени. В работе сравнивается сходимость по итерациям, аппаратный бенчмарк не проводился.

2.4. Метрики

Строки матрицы ошибок соответствуют истинным классам, столбцы — предсказанным; порядок классов 0, 1:

$$C = \begin{pmatrix} TN & FP \\ FN & TP \end{pmatrix}.$$

$$\text{Accuracy} = \frac{TP + TN}{n}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad \text{F1} = \frac{2TP}{2TP + FP + FN}.$$

При нулевом знаменателе Precision, Recall или F1 возвращается 0. Все метрики и матрица ошибок реализованы вручную на NumPy. Accuracy учитывает оба класса; Recall показывает долю найденных положительных объектов, Precision — долю верных положительных прогнозов. F1 объединяет Precision и Recall, но не использует число TN.

3. Псевдокод метода

3.1. Обучение модели

1. Получить X , y , метод, шаг $\alpha > 0$, число итераций T ; положить $w = 0$.
2. Сохранить начальное значение $L(w)$.
3. Для $t = 1, \dots, T$:
 - (a) Вычислить $z = Xw$, $p = \sigma(z)$, $g = X^T(p - y)/n$.
 - (b) Для GD положить $d = g$. Для Ньютона построить H и решить $(H + 10^{-8} I)d = g$.
 - (c) Обновить $w \leftarrow w - \alpha d$, вычислить и сохранить $L(w)$.
 - (d) Если потери не конечны, завершить обучение с сообщением об ошибке.
4. Вернуть веса и историю потерь; прогнозировать класс по порогу 0.5.

3.2. План эксперимента

1. Загрузить CSV; проверить размер, целевые метки, пропуски и дубликаты; сохранить статистику.
2. Стратифицированно разделить данные на train/test с seed 42, затем train на fit/validation с seed 43.
3. На fit оценить медианы, средние и стандартные отклонения. Преобразовать fit и validation с этими параметрами.
4. Обучить каждую из 21 конфигураций на fit. Выбрать минимум validation log loss; при точном равенстве оставить первую конфигурацию в заданном порядке.
5. Зафиксировать выбор до оценки test. Заново оценить предобработку на полном train.
6. Для каждой конфигурации заново обучить модель на train и вычислить метрики на test, как требует задание. Не менять выбор по этим результатам.
7. Сохранить таблицы, индексы разбиения, веса, вероятности и графики.

4. Результаты выполнения

4.1. Данные и предварительная обработка

Исходный набор содержит 768 наблюдений, восемь числовых признаков и целевой столбец. Все наблюдения относятся к женщинам происхождения Pima в возрасте не менее 21 года. Класс 0 представлен 500 объектами, класс 1 — 268. В данных нет явных NaN и полных дубликатов строк.

Признак	Содержание
Pregnancies	Число беременностей.
Glucose	Концентрация глюкозы через 2 часа в тесте толерантности.
BloodPressure	Диастолическое давление, мм рт. ст.
SkinThickness	Толщина кожной складки трицепса, мм.
Insulin	Уровень инсулина через 2 часа, мкЕд/мл.
BMI	Индекс массы тела, кг/м ² .
DiabetesPedigreeFunction	Числовой показатель наследственности.
Age	Возраст, годы.

Таблица 1: Используемые признаки.

Нули в Glucose, BloodPressure, SkinThickness, Insulin и BMI трактуются как отсутствующие измерения. Их количества: 5, 35, 227, 374 и 11 соответственно. Нулевая беременность является допустимым значением и сохраняется. Категориальных входных признаков нет, поэтому дополнительное кодирование не требуется.

Пропуски заполняются медианами обучения; после заполнения выполняется стандартизация $x'_j = (x_j - \mu_j)/s_j$. Для масштабирования используется s_j с `ddof=0`; если $s_j = 0$, масштаб заменяется на 1. Медианы и масштабы test не участвуют в обучении. Статистические графики описывают весь набор, но не используются для выбора признаков или параметров. Все восемь признаков заданы заранее; строки и выбросы не удаляются.




Рис. 1: Баланс классов и отсутствующие измерения.

4.2. Описательная статистика и визуализация

В таблице приведены статистики по наблюдаемым значениям после обозначения отсутствующих измерений как NaN, до заполнения. s — выборочное стандартное отклонение ($ddof=1$); Q1, Q2 и Q3 — квантили 0.25, 0.50 и 0.75.

Признак	n	Среднее	s	min	Q1	Q2	Q3	max
Беременности	768	3.85	3.37	0.00	1.00	3.00	6.00	17.00
Глюкоза	763	121.69	30.54	44.00	99.00	117.00	141.00	199.00
Давление	733	72.41	12.38	24.00	64.00	72.00	80.00	122.00
Кожная складка	541	29.15	10.48	7.00	22.00	29.00	36.00	99.00
Инсулин	394	155.55	118.78	14.00	76.25	125.00	190.00	846.00
ИМТ	757	32.46	6.92	18.20	27.50	32.30	36.60	67.10
Наследственность	768	0.47	0.33	0.08	0.24	0.37	0.63	2.42
Возраст	768	33.24	11.76	21.00	24.00	29.00	41.00	81.00

Таблица 2: Количество, среднее, стандартное отклонение, минимум, максимум и квантили.




Рис. 2: Все требуемые статистики: число наблюдений в заголовках; тонкий отрезок min–max; толстый Q1–Q3; белая отметка — медиана; оранжевая точка и интервал — среднее $\pm s$.




Рис. 3: Гистограммы наблюдаемых значений; среднее отмечено сплошной линией, медиана — пунктиром.

Инсулин и показатель наследственности имеют выраженные правые хвосты, а шкалы признаков существенно различаются. У Insulin отсутствует 374/768 $\approx$ 48.7% измерений, у SkinThickness — 29.6%. Медианное заполнение обеспечивает воспроизводимую базовую обработку, но не восстанавливает неизвестные индивидуальные значения и уменьшает вариативность признаков.

4.3. Разбиение и сетка гиперпараметров

Выборка	Всего	Класс 0	Класс 1
Train	614	400	214
Fit (часть train)	491	320	171
Validation (часть train)	123	80	43
Test	154	100	54

Таблица 3: Стратифицированное разбиение; доля test приблизительно 20%.

Для GD исследованы $\alpha \in \{0.001, 0.01, 0.1, 1.0\}$ и $T \in \{100, 1000, 5000\}$: 12 комбинаций. Для Ньютона исследованы $\alpha \in \{0.1, 0.5, 1.0\}$ и $T \in \{3, 10, 30\}$: 9 комбинаций. Бюджеты различаются, поскольку одна итерация Ньютона использует гессиан; это не сравнение при равных затратах времени.




Рис. 4: Log loss на validation для всех 21 комбинации; меньше — лучше.

4.4. Метрики каждой комбинации

L_{val} рассчитан после обучения на fit; все остальные показатели ниже — после независимого переобучения соответствующей конфигурации на полном train. Поэтому это разные обученные модели одной конфигурации. Жирным выделен вариант, выбранный по L_{val} , а не по test.

α	T	L_{val}	Accuracy	Precision	Recall	F1	L_{test}
0.001	100	0.6778	0.7532	0.6600	0.6111	0.6346	0.6788
0.001	1000	0.5866	0.7532	0.6667	0.5926	0.6275	0.5965
0.001	5000	0.4835	0.7662	0.7045	0.5741	0.6327	0.5103
0.01	100	0.5865	0.7532	0.6667	0.5926	0.6275	0.5964
0.01	1000	0.4626	0.7792	0.7381	0.5741	0.6458	0.4910
0.01	5000	0.4690	0.7727	0.7436	0.5370	0.6237	0.4750
0.1	100	0.4624	0.7792	0.7381	0.5741	0.6458	0.4909
0.1	1000	0.4718	0.7727	0.7436	0.5370	0.6237	0.4744
0.1	5000	0.4720	0.7727	0.7436	0.5370	0.6237	0.4743
1	100	0.4718	0.7727	0.7436	0.5370	0.6237	0.4743
1	1000	0.4720	0.7727	0.7436	0.5370	0.6237	0.4743
1	5000	0.4720	0.7727	0.7436	0.5370	0.6237	0.4743

Таблица 4: Градиентный спуск: все 12 комбинаций.

α	T	L_{val}	Accuracy	Precision	Recall	F1	L_{test}
0.1	3	0.6015	0.7727	0.7568	0.5185	0.6154	0.6080
0.1	10	0.5092	0.7597	0.7297	0.5000	0.5934	0.5199
0.1	30	0.4716	0.7727	0.7436	0.5370	0.6237	0.4764
0.5	3	0.4792	0.7662	0.7368	0.5185	0.6087	0.4890
0.5	10	0.4719	0.7727	0.7436	0.5370	0.6237	0.4744
0.5	30	0.4720	0.7727	0.7436	0.5370	0.6237	0.4743
1	3	0.4718	0.7727	0.7436	0.5370	0.6237	0.4744
1	10	0.4720	0.7727	0.7436	0.5370	0.6237	0.4743
1	30	0.4720	0.7727	0.7436	0.5370	0.6237	0.4743

Таблица 5: Метод Ньютона: все 9 комбинаций.

Наименьший $L_{val} = 0.462361$ получен при GD, $\alpha = 0.1$, $T = 100$. Конфигурация $\alpha = 0.01$, $T = 1000$ очень близка: $L_{val} = 0.462559$. Разница мала и не подтверждает устойчивого преимущества

одной настройки. Порог, признаки и правило выбора не изменялись после просмотра тестовых результатов.

Для выбранной модели Accuracy на test равна $120/154 = 0.7792$. Базовый классификатор, всегда выдающий 0, имеет Accuracy $100/154 = 0.6494$ и Recall/F1, равные нулю. Прирост Accuracy составляет 12.99 процентного пункта. При этом выбранная модель пропускает 23 из 54 положительных объектов: сравнительно высокая Accuracy не означает высокую полноту.

4.5. Влияние гиперпараметров и сходимость




Рис. 5: Фактическая история train log loss. Для GD показаны запуски по 5000 шагов, для Ньютона — по 30.

1. **Шаг GD.** При $\alpha = 0.001$, $T = 100$ train log loss составляет 0.6781, то есть обучение далеко от минимума. При увеличении бюджета до 5000 он снижается до 0.4958. При $\alpha = 1$ уже 100 шагов дают около 0.46347. В проверенной сетке расходимости не обнаружено; это не гарантия для произвольных шагов и данных.
2. **Число итераций.** Увеличение бюджета уменьшает train log loss, но не обязательно улучшает F1. Например, для GD с $\alpha = 0.1$ переход со 100 на 1000 шагов снижает test log loss с 0.4909 до 0.4744, одновременно снижая F1 с 0.6458 до 0.6237. Вероятностная потеря и пороговые метрики оценивают разные свойства.
3. **Ньютон.** При полном шаге уже три итерации дают train log loss 0.463469, а десять — 0.463467. Демпфирование $\alpha = 0.1$ замедляет сходимость: после трёх шагов потери 0.6014. По числу итераций Ньютон сходится быстрее GD на данном наборе.
4. **Обобщение.** После достаточного обучения GD и Ньютон дают практически одинаковые потери и одинаковые тестовые классификации. Однако минимум validation достигается раньше полной сходимости. Это согласуется с эффектом ограничения числа итераций как неявной регуляризации, но одного разбиения недостаточно для общего вывода.

4.6. Выбранная модель и интерпретация




Рис. 6: Матрица ошибок и веса модели GD, $\alpha = 0.1$, $T = 100$.

Признак	w_j	$\exp(w_j)$
Intercept	-0.6499	0.5221
Pregnancies	0.2008	1.2224
Glucose	0.8282	2.2893
BloodPressure	0.0469	1.0480
SkinThickness	0.0994	1.1045
Insulin	0.1375	1.1474
BMI	0.3995	1.4911
Наследственность	0.2116	1.2356
Age	0.1829	1.2007

Таблица 6: Параметры после стандартизации. Intercept — свободный член.

Коэффициент Glucose равен 0.8282: увеличение стандартизованного признака на единицу при фиксированных остальных признаках умножает оценённые шансы на $e^{0.8282} \approx 2.2893$. Это отношение шансов, а не множитель вероятности. Положительные коэффициенты описывают условные связи внутри данной модели и не доказывают причинность. Признаки после заполнения масштабируются по train, поэтому единица означает одно стандартное отклонение заполненного обучающего признака.

4.7. Проверка реализации

Выполнены шесть автоматических проверок: сигмоида и потери на логитах ± 1000 ; сравнение градиента и гессиана с центральными конечными разностями; ручной пример матрицы ошибок и метрик; отсутствие пересечения частей разбиения и воспроизводимость индексов; неизменность параметров предобработки при обработке новых данных; совпадение решений GD и Ньютона на невырожденном синтетическом примере. Все проверки прошли. Синтетические данные используются только для проверки, а не для приведённых результатов эксперимента.

Предобработка, обучение и метрики реализованы на NumPy и Pandas; Matplotlib применяется для графиков. Готовые алгоритмы классификации, разбиения и расчёта метрик не используются.

5. Примеры использования метода

5.1. Прогнозы на отложенных объектах

Ниже приведены первые шесть объектов `test` в порядке исходного индекса CSV. Индексация начинается с нуля; значения не отобраны по правильности прогнозов. Вероятности получены сохранённой моделью с порогом 0.5.

Индекс строки	Истина	Вероятность	Прогноз
1	0	0.0908	0
13	1	0.9033	1
15	1	0.2271	0
17	1	0.2281	0
26	1	0.6473	1
39	1	0.6460	1

Таблица 7: Фактические примеры из тестовой выборки.

Для нового объекта применяются медианы и масштабы, рассчитанные по обучающей части набора. Затем к вектору признаков добавляется единица, вычисляется $p = \sigma(Xw)$ и по порогу 0.5 назначается класс.

5.2. Ситуации применения

Логистическая регрессия полезна как интерпретируемая базовая модель бинарного отклика: вероятность оттока пользователя, отклика на предложение или принадлежности сообщения к спаму. Она удобна, когда нужна компактная модель и объяснение связи признаков с логарифмом шансов. Для таких задач следует заново подобрать данные, предобработку, порог и протокол оценки.

В данном эксперименте решается учебная задача воспроизведения меток исторического набора. Результат не проверен на других популяциях и не предназначен для постановки диагноза. Большая доля пропусков и Recall 0.5741 ограничивают практическую применимость. Для реального использования нужны внешняя проверка, оценка калибровки и выбор порога по стоимости ошибок на независимой валидации.

6. Сравнение методов

6.1. Сравнительный анализ

Численно сравнивались два способа оптимизации одной логистической модели. Ньютон быстрее достигает минимума по количеству шагов, GD проще и дешевле на каждом шаге. При достаточной сходимости их качество практически совпадает. Выбор GD с ограниченным бюджетом в этом опыте связан с validation log loss, а не с принципиально большей выразительностью.

Связь с остальными методами модуля можно описать качественно; сопоставимых запусков k-NN и деревьев на данном разбиении не проводилось.

Метод	Подходящая задача	Основное ограничение
Линейная регрессия	Количественный отклик и линейные связи.	Не ограничивает прогноз интервалом вероятностей.
k-NN	Классификация по близости объектов, локальные нелинейные зависимости.	Чувствительность к масштабу и выбору расстояния; стоимость поиска соседей.
Дерево решений	Нелинейные правила и взаимодействия признаков.	Возможное переобучение и нестабильность разбиений.
Логистическая регрессия	Бинарный отклик, вероятности и интерпретация шансов.	Линейная граница в пространстве выбранных признаков.

Таблица 8: Качественное сравнение назначения методов модуля.

6.2. Примеры лучшего использования

Для прогноза непрерывной стоимости естественна линейная регрессия; для локально похожих объектов при разумной метрике можно рассматривать k-NN; для правил с порогами и взаимодействиями — дерево. При бинарном отклике и необходимости объяснять вклад признаков логистическая регрессия даёт удобную отправную точку. Эти рекомендации описывают свойства методов, а не установленное экспериментом превосходство на всех данных.

7. Заключение

Поставленная задача выполнена: загружен реальный датасет, исследована статистика, обработаны отсутствующие измерения, реализована логистическая регрессия с нуля и оценена 21 комбинация гиперпараметров. Градиент, гессиан и метрики проверены независимо от основного эксперимента.

По заранее выбранному критерию validation log loss отобрана конфигурация GD с $\alpha = 0.1$, $T = 100$. После обучения на 614 объектах она дала Accuracy 77.92%, Precision 73.81%, Recall 57.41% и F1 64.58% на 154 тестовых объектах. На практике существенны не только правильные классификации, но и 23 пропущенных положительных объекта.

Метод Ньютона оказался эффективнее по числу итераций до близкого к минимуму train log loss. Увеличение числа шагов не обеспечивало улучшения всех метрик. Результаты относятся к фиксированному разбиению: для более надёжного выбора параметров целесообразны повторная стратифицированная кросс-валидация, исследование регуляризации и независимая проверка качества вероятностей. Настройки нельзя объявлять универсально лучшими на основании этого опыта.