Федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский университет ИТМО»

Системы искусственного интеллекта

Лабораторная работа №5

Деревья решений

Вариант — нечётный номер

Выполнил
Чэнь Хаолинь P3316 407960

Преподаватель
Болдырева Елена Александровна

г. Санкт-Петербург, 2026

Содержание

1 Цель работы и теоретические сведения **2**

2 Данные и разбиение **2**

3 Реализация дерева и метрик **3**

3.1 Обучение и прогнозирование 3

3.2 Метрики и площадь под кривой 4

4 Структура дерева и важность признаков **5**

5 Качество классификации **6**

5.1 Кривые ROC и PR 6

5.2 Влияние порога и переобучение 7

6 Сравнение с критерием Джини **7**

7 Заключение **7**

1. Цель работы и теоретические сведения

Цель работы — реализовать многоветвевое дерево решений для бинарной классификации по категориальным признакам. Требуется оценить качество на обучающей и тестовой выборках, построить ROC- и PR-кривые, вычислить площади под ними методом трапеций и исследовать влияние порога на ошибки. В дополнительном эксперименте сравниваются критерии энтропии и Джини.

Пусть S — множество объектов в узле, а p_c — доля класса c. Для каждого значения v признака A формируется подмножество S_v. Энтропия узла и информационный выигрыш разбиения равны

$$H(S) = -\sum_{c=0}^{1} p_c \log_2 p_c, \qquad IG(S, A) = H(S) - \sum_{v} \frac{|S_v|}{|S|} H(S_v).$$

Слагаемое $p_c \log_2 p_c$ при $p_c = 0$ принимается равным нулю. Для критерия Джини используется та же разность между неопределённостью родительского узла и взвешенной неопределённостью потомков, где $G(S) = 1 - \sum_{c=0}^{1} p_c^2$ заменяет $H(S)$.

В каждом узле выбирается доступный признак с наибольшим положительным выигрышем. Выбранный признак исключается из дальнейших разбиений на этом пути. Узел становится листом, если все объекты принадлежат одному классу, признаки закончились или положительного выигрыша нет. Оценка p_1 берётся из достигнутого листа. При отсутствии ветви для значения признака используется p_1 текущего узла. Прогноз равен единице при $p_1 \geq t$, где стандартный порог $t = 0{,}5$.

2. Данные и разбиение

Набор Higher Education Students Performance Evaluation содержит 145 наблюдений. Класс 1 соответствует `OUTPUT Grade` ≥ 3, класс 0 — остальным оценкам. `Student ID` и `OUTPUT Grade` исключены из входных признаков. Все 31 оставшийся признак рассматриваются как категориальные. Для пустых значений и «?» предусмотрена отдельная категория «пропуск». В обработанных данных пропусков не оказалось.

Таблица 1: Распределение объектов по выборкам

Выборка	Всего	Класс 0	Класс 1	Доля класса 1
Полная	145	67	78	53,8 %
Обучающая	116	54	62	53,4 %
Тестовая	29	13	16	55,2 %

Объекты перемешаны внутри каждого класса с начальным состоянием генератора 42. При разбиении 80/20 выделено 29 тестовых объектов, из них 16 положительных по округлённой доле класса 1. Из 31 признака один раз отобраны $\lfloor \sqrt{31} \rfloor = 5$ без возвращения с начальным состоянием 43. В общий для обоих деревьев набор вошли `Sex` (пол), `Additional work` (дополнительная работа), `Accomodation type in Cyprus` (тип жилья), `Preparation to midterm exams 1` (подготовка к промежуточным экзаменам) и `Taking notes in classes` (конспектирование).

3. Реализация дерева и метрик

3.1. Обучение и прогнозирование

Функция `fit` строит дерево рекурсивно. Выигрыши в пределах допуска 10^{-12} считаются равными, поэтому при равенстве сохраняется первый признак в порядке столбцов. Функция `route` возвращает узел, чья доля класса 1 используется для прогноза.

```
"""Многоветвевое дерево для категориальных признаков."""

from collections import defaultdict
from dataclasses import dataclass, field
from math import log2


def entropy(p):
    if p in (0, 1):
        return 0.0
    return -p * log2(p) - (1 - p) * log2(1 - p)


def gini(p):
    return 1 - p**2 - (1 - p)**2


@dataclass
class Node:
    probability: float
    size: int
    feature: str | None = None
    gain: float = 0.0
    children: dict[str, "Node"] = field(default_factory=dict)


def fit(rows, labels, features, impurity=entropy):
    """Строит дерево, используя только переданные обучающие объекты."""
    def grow(indices, remaining):
        p = sum(labels[i] for i in indices) / len(indices)
        node = Node(p, len(indices))
        if p in (0, 1) or not remaining:
            return node

        parent_impurity = impurity(p)
        best_groups = {}
        for feature in remaining:
            groups = defaultdict(list)
            for i in indices:
                groups[rows[i][feature]].append(i)
            # Неопределённость после разбиения взвешена по размерам ветвей.
            after = sum(
                len(group) / len(indices)
                * impurity(sum(labels[i] for i in group) / len(group))
                for group in groups.values()
            )
            gain = parent_impurity - after
            # Игнорируем округление около нуля. При равенстве берём первый признак.
            if gain > node.gain + 1e-12:
                node.feature, node.gain, best_groups = feature, gain, groups

        if node.feature is not None:
            unused = tuple(f for f in remaining if f != node.feature)
            node.children = {
                value: grow(best_groups[value], unused) for value in sorted(best_groups)
            }
        return node

    return grow(range(len(rows)), tuple(features))


def route(node, row):
    """Возвращает лист или внутренний узел, если нужная ветвь отсутствует."""
    while node.feature is not None:
        child = node.children.get(row[node.feature])
        if child is None:
            break
        node = child
    return node
```

3.2. Метрики и площадь под кривой

Для порога t вычисляются числа TP, FP, TN и FN. Точность положительных прогнозов обозначена P, полнота — R.

$$\text{Accuracy} = \frac{TP + TN}{N}, \qquad P = \frac{TP}{TP + FP}, \qquad R = \frac{TP}{TP + FN}, \qquad \text{FPR} = \frac{FP}{FP + TN}.$$

При пустом наборе положительных прогнозов precision в таблице метрик принимается равной нулю. Ордината начальной точки PR-кривой по соглашению равна 1.

```
"""Бинарные метрики и точки кривых без библиотечных реализаций."""

from dataclasses import dataclass


@dataclass
class Confusion:
    tp: int
    fp: int
    tn: int
    fn: int

    @property
    def accuracy(self):
        return (self.tp + self.tn) / (self.tp + self.fp + self.tn + self.fn)

    @property
    def precision(self):
        return self.tp / (self.tp + self.fp) if self.tp + self.fp else 0.0

    @property
    def recall(self):
        return self.tp / (self.tp + self.fn) if self.tp + self.fn else 0.0

    @property
    def fpr(self):
        return self.fp / (self.fp + self.tn) if self.fp + self.tn else 0.0


def evaluate(labels, scores, threshold=0.5):
    tp = fp = tn = fn = 0
    for label, score in zip(labels, scores, strict=True):
        prediction = int(score >= threshold)
        tp += int(label == prediction == 1)
        fp += int(label == 0 and prediction == 1)
        tn += int(label == prediction == 0)
        fn += int(label == 1 and prediction == 0)
    return Confusion(tp, fp, tn, fn)


def threshold_points(labels, scores, leaf_scores):
    # Значения во внутренних узлах тоже возможны при отсутствии ветви.
    thresholds = {0.0, 1.0, *leaf_scores, *scores}
    # При +inf нет положительных прогнозов даже при наличии оценки 1.
    return [
        (threshold, evaluate(labels, scores, threshold))
        for threshold in [float("inf"), *sorted(thresholds, reverse=True)]
    ]


def curve_points(points):
    roc = [(m.fpr, m.recall) for _, m in points]
    # При пустом наборе положительных прогнозов используем (0, 1) для PR.
    pr = [(m.recall, m.precision if m.tp + m.fp else 1.0) for _, m in points]
    return roc, pr


def trapezoidal_auc(points):
    # Стабильная сортировка по x сохраняет порядок порогов при равных x.
    ordered = sorted(points, key=lambda point: point[0])
    return sum(
        (right_x - left_x) * (left_y + right_y) / 2
        for (left_x, left_y), (right_x, right_y) in zip(ordered, ordered[1:])
    )
```

4. Структура дерева и важность признаков

Глубина энтропийного дерева равна 5 при нулевой глубине корня. Дерево содержит 32 листа. Слева от стрелки указано значение входящей ветви. Поле `n` содержит число обучающих объектов, `p1` — долю класса 1, `IG` — информационный выигрыш. Ниже показаны узлы до глубины 3, многоточием отмечены продолжения ветвей.

```
Корень -> Sex [IG=0.04546, n=116, p1=0.5345]
  1 -> Taking notes in classes [IG=0.06670, n=45, p1=0.3778]
    1 -> лист [n=3, p1=0.0000]
    2 -> Additional work [IG=0.08170, n=18, p1=0.5000]
      1 -> Accomodation type in Cyprus [IG=0.07278, n=9, p1=0.6667] ...
      2 -> Accomodation type in Cyprus [IG=0.16775, n=9, p1=0.3333] ...
    3 -> Additional work [IG=0.13955, n=24, p1=0.3333]
      1 -> Accomodation type in Cyprus [IG=0.19351, n=10, p1=0.1000] ...
      2 -> Preparation to midterm exams 1 [IG=0.25698, n=14, p1=0.5000] ...
  2 -> Preparation to midterm exams 1 [IG=0.05207, n=71, p1=0.6338]
    1 -> Additional work [IG=0.03978, n=56, p1=0.6429]
      1 -> Accomodation type in Cyprus [IG=0.04076, n=17, p1=0.4706] ...
      2 -> Taking notes in classes [IG=0.07504, n=39, p1=0.7179] ...
    2 -> Accomodation type in Cyprus [IG=0.29990, n=11, p1=0.4545]
      1 -> Additional work [IG=0.09236, n=8, p1=0.3750] ...
      2 -> лист [n=2, p1=1.0000]
      4 -> лист [n=1, p1=0.0000]
    3 -> лист [n=4, p1=1.0000]
```

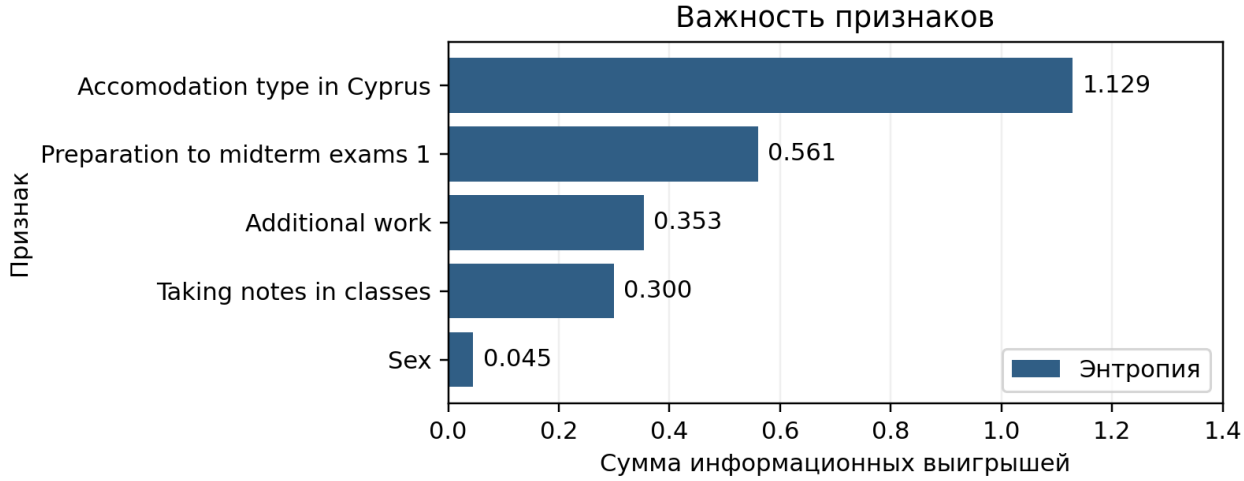


Рис. 1: Суммарный информационный выигрыш по признакам

Важность признака равна сумме его выигрышей во всех узлах, где он использован, без дополнительного взвешивания по размеру узла. Наибольшие значения дали тип жилья (1,129) и подготовка к экзаменам (0,561). Признак `Sex` дал лучший выигрыш в корне, однако использован только в одном узле.

5. Качество классификации

Таблица 2: Метрики двух деревьев при пороге $t = 0{,}5$

Критерий	Выборка	TP	FP	TN	FN	Accuracy	Precision	Recall
Энтропия	Обучение	52	18	36	10	0,759	0,743	0,839
Энтропия	Тест	8	3	10	8	0,621	0,727	0,500
Джини	Обучение	52	18	36	10	0,759	0,743	0,839
Джини	Тест	8	3	10	8	0,621	0,727	0,500

При пороге 0,5 энтропийное дерево пропустило 8 из 16 объектов класса 1 (ошибки второго рода). Ложноположительных ответов было 3 на 13 объектов класса 0 (ошибки первого рода).

5.1. Кривые ROC и PR

ROC строится в координатах (FPR, R), PR — в координатах (R, P). Порог последовательно принимает уникальные доли класса 1 в листьях, значения 0 и 1, а также доли внутренних узлов, фактически возвращённые на тесте при отсутствии ветви. Дополнительный порог $+\infty$ задаёт точки $(0, 0)$ для ROC и $(0, 1)$ для PR. При пороге 0 к классу 1 относятся все объекты и ROC достигает точки $(1, 1)$. Горизонтальный пунктир на PR соответствует доле положительного класса $16/29$.

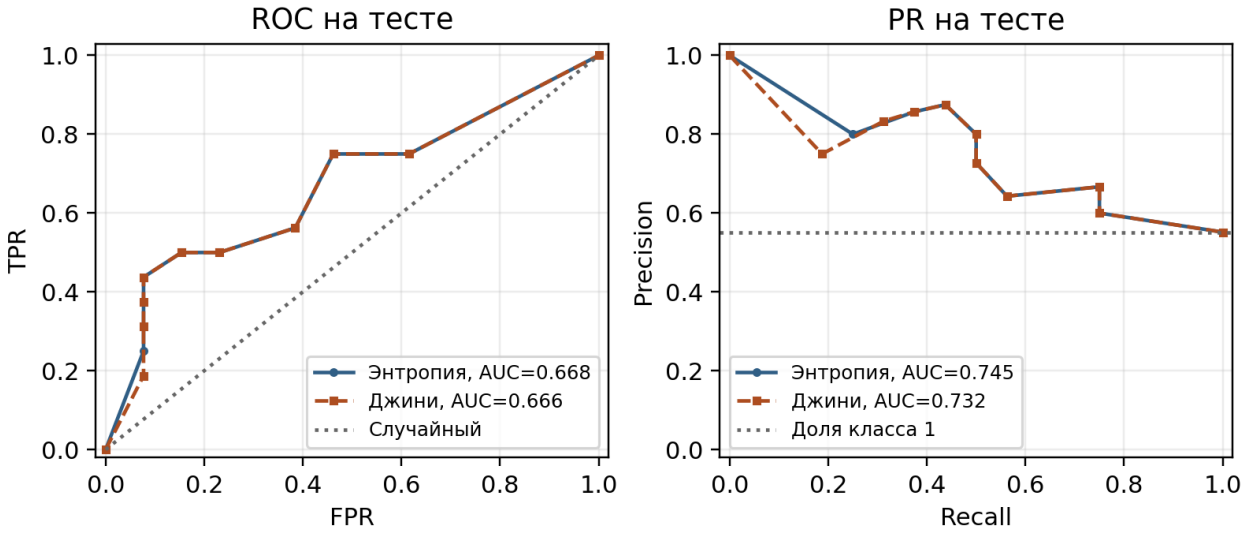


Рис. 2: ROC- и PR-кривые на тестовой выборке

Площадь под каждой кривой вычислена суммированием площадей трапеций.

$$\mathrm{AUC} = \sum_i (x_{i+1} - x_i) \frac{y_{i+1} + y_i}{2}.$$

Перед интегрированием точки устойчиво сортируются по x. При равных абсциссах сохраняется порядок убывания порогов. Для энтропийного дерева ROC-AUC равна 0,668, PR-AUC равна 0,745.

5.2. Влияние порога и переобучение

Таблица 3: Ошибки энтропийного дерева при изменении порога на тесте

Порог	FP	FN	Precision	Recall
1/3	6	4	0,667	0,750
0,50	3	8	0,727	0,500
0,75	1	9	0,875	0,438
1,00	1	12	0,800	0,250

При повышении порога с 0,50 до 0,75 число FP снизилось с 3 до 1, а FN выросло с 8 до 9. При дальнейшем повышении порога до 1,00 число FP осталось равным 1, а TP упало с 7 до 4, поэтому precision снизилась с 0,875 до 0,800. Снижение порога до 1/3 позволило найти 12 из 16 положительных объектов при 6 ложных срабатываниях.

Accuracy энтропийного дерева снизилась с 0,759 на обучении до 0,621 на тесте, то есть на 13,8 процентного пункта. Recall упала с 0,839 до 0,500, а precision — с 0,743 до 0,727. Разрыв и листья, построенные по одному обучающему объекту, указывают на переобучение. При 29 тестовых объектах величина разрыва чувствительна к разбиению.

6. Сравнение с критерием Джини

Дерево Джини использует те же пять признаков, имеет глубину 5 и 32 листа. В обоих деревьях корень делит объекты по `Sex`. Структура ветви `Sex` $= 1$ совпадает. При `Sex` $= 2$ первое разбиение по Джини использует тип жилья, а по энтропии — подготовку к экзаменам. Для одного тестового объекта дерево Джини вернуло долю класса 1 во внутреннем узле из-за отсутствующей ветви.

При пороге 0,5 метрики и числа ошибок совпали на обеих выборках. У дерева Джини ROC-AUC равна 0,666, PR-AUC равна 0,732. На этом разбиении энтропия дала площади больше примерно на 0,002 и 0,013 соответственно.

7. Заключение

Наибольший вклад в разбиения энтропийного дерева внесли тип жилья и подготовка к экзаменам. При стандартном пороге дерево обнаружило половину положительных объектов тестовой выборки. Снижение порога сокращает число пропусков ценой дополнительных ложных срабатываний. Падение accuracy и recall на тесте указывает на ограниченную переносимость обучающих разбиений. Замена энтропии на критерий Джини изменила часть ветвей, сохранив разрыв между обучением и тестом.