

Федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский университет ИТМО»

Отчёт по учебно-исследовательской работе № 1

по дисциплине «Моделирование»

**«Обработка результатов измерений:
статистический анализ числовой последовательности»**

Вариант 263

Выполнил:
Чэнь Хаолинъ Р3316

Проверил:
Тропченко Андрей Александрович

г. Санкт-Петербург, 2026

Содержание

1	Постановка задачи	2
2	Методика расчёта	2
3	Числовые характеристики исходной последовательности	3
4	Характер последовательности и гистограмма	4
5	Автокорреляционный анализ	5
6	Аппроксимация по двум моментам	6
7	Алгоритм генерации и характеристики новой выборки	6
7.1	Программа обработки и контрольный запуск	7
8	Сопоставление последовательностей и распределений	9
8.1	Корреляция между исходной и новой последовательностями	10
9	Заключение	10

1. Постановка задачи

Цель работы — исследовать числовую последовательность методами математической статистики, определить её корреляционные свойства и подобрать аппроксимирующий закон распределения по двум моментам.

Требуется обработать первые 10, 20, 50, 100, 200 и 300 значений. Для каждого объёма выборки следует найти оценки математического ожидания, дисперсии, среднеквадратического отклонения, коэффициента вариации и доверительные интервалы для среднего при вероятностях 0.90, 0.95 и 0.99. Полученные характеристики необходимо сравнить с результатами для 300 наблюдений.

Далее необходимо исследовать график последовательности, её автокорреляцию и распределение частот; подобрать распределение по двум моментам; реализовать генератор, сформировать новую последовательность из 300 значений и сравнить её числовые характеристики, автокорреляцию, гистограмму и попарную корреляцию с исходными наблюдениями.

Исследуемая последовательность содержит 300 положительных значений. Их порядок при обработке сохранён. Первые пять наблюдений: 388.730737, 122.364363, 192.423860, 107.281584, 127.827354. Минимальное значение равно 20.670414, максимальное — 1175.257487. Единицы измерения не заданы. Выборки объёмов $n \in \{10, 20, 50, 100, 200, 300\}$ состоят из первых n элементов, поэтому они вложены друг в друга. Значения, рассчитанные для 300 наблюдений, используются как сравнительный ориентир, а не как известные истинные параметры.

2. Методика расчёта

Среднее, несмещённая дисперсия, стандартное отклонение и коэффициент вариации рассчитываются по формулам

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i, \quad s_n^2 = \frac{\sum_{i=1}^n (x_i - \bar{x}_n)^2}{n-1}, \quad s_n = \sqrt{s_n^2}, \quad v_n = \frac{s_n}{\bar{x}_n}. \quad (1)$$

Для среднего используем приближённый доверительный интервал:

$$I_p = [\bar{x}_n - \varepsilon_p; \bar{x}_n + \varepsilon_p], \quad \varepsilon_p = z_{(1+p)/2} \frac{s_n}{\sqrt{n}}. \quad (2)$$

Здесь z_q — квантиль стандартного нормального распределения; $z_{0.95} = 1.644854$, $z_{0.975} = 1.959964$, $z_{0.995} = 2.575829$. В таблицах записана полуширина $\pm \varepsilon_p$.

Нормальная аппроксимация опирается на независимость наблюдений и центральную предельную теорему. При $n = 10, 20$, особенно для асимметричного распределения, покрытие может отличаться от номинального. Интервал Стьюдента также не является точным для ненормальной исходной величины. Интервалы характеризуют неопределённость среднего, а не разброс отдельных наблюдений.

Для любого показателя A относительное отклонение определено со знаком:

$$\Delta(A; A_0) = 100 \frac{A - A_0}{|A_0|} \%. \quad (3)$$

В форме 1 $A_0 = A_{x,300}$, в форме 2 $A_0 = A_{x,n}$ при том же n . Для положительных характеристик модуль в знаменателе ничего не меняет.

3. Числовые характеристики исходной последовательности

Таблица 1: Форма 1. Характеристики исходной последовательности и отклонения от выборки $n = 300$

Показатель	10	20	50	100	200	300
$\bar{x}$	273.9943	305.9489	275.9083	276.9415	265.0886	276.4782
$\Delta, \%$	-0.90	10.66	-0.21	0.17	-4.12	0.00
s^2	36203.5566	41597.0344	25268.5370	25957.9300	24872.8517	29298.1731
$\Delta, \%$	23.57	41.98	-13.75	-11.40	-15.10	0.00
s	190.2723	203.9535	158.9608	161.1146	157.7113	171.1671
$\Delta, \%$	11.16	19.15	-7.13	-5.87	-7.86	0.00
v	0.6944	0.6666	0.5761	0.5818	0.5949	0.6191
$\Delta, \%$	12.17	7.68	-6.94	-6.03	-3.90	0.00
$\varepsilon_{0.90}$	± 98.9698	± 75.0142	± 36.9771	± 26.5010	± 18.3432	± 16.2550
$\Delta, \%$	508.86	361.48	127.48	63.03	12.85	0.00
$\varepsilon_{0.95}$	± 117.9298	± 89.3849	± 44.0609	± 31.5779	± 21.8573	± 19.3690
$\Delta, \%$	508.86	361.48	127.48	63.03	12.85	0.00
$\varepsilon_{0.99}$	± 154.9861	± 117.4717	± 57.9058	± 41.5004	± 28.7253	± 25.4552
$\Delta, \%$	508.86	361.48	127.48	63.03	12.85	0.00

При $n = 300$ получены $\bar{x} = 276.478202$, $s^2 = 29298.173051$, $s = 171.167091$, $v = 0.619098$. Разброс существенен: стандартное отклонение составляет около 62% среднего. При увеличении объёма оценки в целом стабилизируются, но отдельные отклонения не обязаны уменьшаться монотонно. Для полной выборки доверительные интервалы имеют вид:

$$I_{0.90} = [260.223205; 292.733200],$$

$$I_{0.95} = [257.109179; 295.847226],$$

$$I_{0.99} = [251.022990; 301.933415].$$

При $p = 0.95$ относительная полуширина составляет $19.369024/276.478202 \cdot 100\% = 7.0056\%$. Это отличается от строки отклонения полуширины в форме 1: там сравниваются две оценки, а здесь оценивается точность среднего.




Рис. 1: Зависимость полуширины доверительного интервала от объёма выборки

При фиксированном n более высокая доверительная вероятность требует более широкого интер-

вала. При росте n множитель $1/\sqrt{n}$ уменьшает его ширину, хотя одновременно меняется оценка s_n .

4. Характер последовательности и гистограмма



Рис. 2: График 1. Значения исходной последовательности

На графике наблюдаются нерегулярные колебания с отдельными большими значениями. Последовательность не является монотонно возрастающей или убывающей. Повторяющийся период визуально не выделяется. В качестве дополнительной проверки оценён линейный тренд: наклон 0.109897 на один номер наблюдения, двустороннее p -значение 0.3364. На уровне 0.05 значимого линейного тренда не обнаружено. Этот результат сам по себе не доказывает стационарность.




Рис. 3: График 2. Частоты исходной последовательности в 10 равных интервалах

Гистограмма показывает положительную асимметрию и правый хвост. Для сопоставления обеих выборок используются одинаковые 10 интервалов от нуля до общего максимума. Интервалы замкнуты слева и открыты справа, последний включает правую границу. Выбор числа интервалов влияет на внешний вид гистограммы, поэтому дополнительно рассматривается расстояние между эмпирической и теоретической функциями распределения.

5. Автокорреляционный анализ

Используем корреляцию Пирсона двух укороченных последовательностей $(x_1, \dots, x_{N-k})$ и $(x_{1+k}, \dots, x_N)$:

$$r_x(k) = \frac{\sum_{i=1}^{N-k} (x_i - \bar{x}_L)(x_{i+k} - \bar{x}_R)}{\sqrt{\sum_{i=1}^{N-k} (x_i - \bar{x}_L)^2 \sum_{i=1}^{N-k} (x_{i+k} - \bar{x}_R)^2}}. \quad (4)$$

Средние $\bar{x}_L, \bar{x}_R$ рассчитаны отдельно для соответствующих отрезков. В таблице приведены обязательные сдвиги 1–10, на графике — 1–60. При больших сдвигах число пар уменьшается и оценка становится менее устойчивой.

Таблица 2: Форма 3. Автокорреляция исходной и сгенерированной последовательностей

k	$r_x(k)$	$r_y(k)$	Δr	$\Delta, \%$
1	-0.0327	-0.0340	-0.0013	-3.90
2	-0.0317	-0.0461	-0.0144	-45.34
3	-0.0440	0.0203	0.0643	146.16
4	-0.0031	-0.1060	-0.1029	-3313.46
5	0.0225	-0.0921	-0.1147	-508.85
6	0.0470	0.0053	-0.0417	-88.81
7	0.0330	-0.0029	-0.0359	-108.81
8	0.0790	0.0310	-0.0480	-60.73
9	0.0632	-0.0755	-0.1387	-219.60
10	-0.0445	0.1123	0.1569	352.15

Здесь $\Delta r = r_y - r_x$, а $\Delta, \% = 100(r_y - r_x)/|r_x|$. Процентные различия приведены согласно форме задания, но при $r_x \approx 0$ они неустойчивы и не характеризуют качество модели. Например, малый знаменатель при $k = 4$ даёт большое процентное отличие при умеренной абсолютной разности.




Рис. 4: Автокорреляционные функции. Пунктир: ориентировочные поточечные границы $\pm 1.96/\sqrt{300} = \pm 0.1132$

Границы являются диагностическим ориентиром для белого шума, а не одновременной гарантией для всех сдвигов. На сдвигах 1–10 все коэффициенты обеих последовательностей находятся

внутри этих границ. Регулярной периодической структуры не выявлено. Нулевая линейная корреляция не доказывает независимость или случайность.

Дополнительно применён критерий Льюнга–Бокса для первых 10 сдвигов:

$$Q = N(N+2) \sum_{k=1}^{10} \frac{\hat{\rho}_k^2}{N-k}, \quad \hat{\rho}_k = \frac{\sum_{i=1}^{N-k} (x_i - \bar{x})(x_{i+k} - \bar{x})}{\sum_{i=1}^N (x_i - \bar{x})^2}. \quad (5)$$

Для этого критерия используется стандартная нормировка с общим средним, отличающаяся от корреляции укороченных отрезков в форме 3. Для исходной последовательности $Q = 5.8741$, $p = 0.8257$; для сгенерированной $Q = 12.5094$, $p = 0.2524$. При уровне значимости 0.05 гипотеза отсутствия автокорреляции на первых 10 сдвигах не отвергается для обеих выборок. Совместно с графиками это позволяет использовать модель независимых случайных наблюдений в рамках работы, но не устанавливает механизм происхождения исходных данных.

6. Аппроксимация по двум моментам

Второй начальный выборочный момент равен

$$\hat{m}_{2,\text{raw}} = \frac{1}{300} \sum x_i^2 = 105640.708853.$$

Для согласования с несмещённой дисперсией из формы 1 используем оценки моментов $m_1 = \bar{x}$ и $m_2 = \bar{x}^2 + s^2 = 105738.369429$. Их отличие от сырого момента равно $s^2/300 = 97.660577$. Тем самым закон согласован с оценённой дисперсией s^2 , а не с дисперсией с делителем N .

Получено $v^2 = 0.3832823$, $1/v^2 \approx 2.6090$. Экспоненциальный закон требует $v = 1$, гиперэкспоненциальный — $v \geq 1$. Равномерный закон, согласованный с этими моментами, имел бы левую границу $\bar{x} - \sqrt{3}s \approx -19.99$, то есть допускал бы отрицательные значения. У неотрицательного равномерного распределения $v \leq 1/\sqrt{3} \approx 0.5774$. Нормированный закон Эрланга порядка 3 имеет $v = 1/\sqrt{3}$ и не воспроизводит найденную вариацию точно.

Выберем гипоекспоненциальный закон: сумму трёх независимых экспоненциальных стадий с двумя одинаковыми средними:

$$Y = E_1 + E_2 + E_3, \quad E_1, E_2 \sim \text{Exp}(1/a), \quad E_3 \sim \text{Exp}(1/b).$$

Условия согласования моментов: $2a + b = m_1$, $2a^2 + b^2 = s^2$. Выбранное решение

$$a = \frac{m_1 - \sqrt{(3s^2 - m_1^2)/2}}{3} = 66.933397, \quad b = m_1 - 2a = 142.611408. \quad (6)$$

Оно положительно при $1/3 \leq v^2 < 1$. Интенсивности равны $\lambda_a = 0.0149402248$, $\lambda_b = 0.0070120617$. Проверка даёт $E[Y] = 276.478202$ и $D[Y] = 29298.173051$. Два момента не определяют распределение однозначно: выбран простой положительный фазовый закон с минимальным необходимым числом экспоненциальных стадий, так как для суммы k таких стадий $v^2 \geq 1/k$.

7. Алгоритм генерации и характеристики новой выборки

Плотность выбранного закона при $t \geq 0$ имеет вид

$$f_Y(t) = \frac{\lambda_a^2 \lambda_b}{(\lambda_a - \lambda_b)^2} e^{-\lambda_b t} \left[1 - e^{-(\lambda_a - \lambda_b)t} (1 + (\lambda_a - \lambda_b)t) \right], \quad (7)$$

а при $t < 0$ равна нулю. Она получена свёрткой плотности Эрланга порядка 2 и экспоненциальной плотности. В программе график вычисляется через эквивалентное фазовое представление, чтобы избежать вычитания близких чисел при малом t .

Для каждого i генерируются независимые равномерные числа $U_{i1}, U_{i2}, U_{i3} \in [0, 1)$, после чего

$$Y_i = -a \ln(1 - U_{i1}) - a \ln(1 - U_{i2}) - b \ln(1 - U_{i3}). \quad (8)$$

Для трёх стадий применён генератор равномерных чисел с фиксированным начальным состоянием. Сформированы 300 значений без последующей подгонки или масштабирования. При другом начальном состоянии получится новая реализация того же закона. В форме 2 проценты рассчитаны относительно исходной выборки того же объёма.

7.1. Программа обработки и контрольный запуск

Программа последовательно считывает 300 измерений, определяет параметры a и b , формирует новую последовательность методом обратной функции распределения и для первых $n = 10, 20, 50, 100, 200, 300$ элементов каждой последовательности вычисляет $\bar{x}_n$, s_n^2 , s_n , v_n и полуширины трёх доверительных интервалов. Затем она рассчитывает автокорреляцию при сдвигах 1–10, частоты в десяти общих интервалах и коэффициент корреляции исходной и сгенерированной последовательностей. Полный исполняемый пример приведён в листинге 1.

Листинг 1. Генерация и расчёт числовых характеристик

```

1 """Демонстрация генерации и расчёта характеристик для защиты УИР 1."""
2 from pathlib import Path
3 from statistics import NormalDist
4 import math
5 import numpy as np
6
7 DATA = Path(__file__).resolve().parents[2] / 'data' / 'measurements.csv'
8 SIZES = (10, 20, 50, 100, 200, 300)
9 PROBABILITIES = (0.90, 0.95, 0.99)
10
11
12 def parameters(mean, variance):
13     a = (mean - math.sqrt((3 * variance - mean**2) / 2)) / 3
14     b = mean - 2 * a
15     return a, b
16
17
18 def generate(a, b, size, seed):
19     u = np.random.default_rng(seed).random((size, 3))
20     return (-np.log1p(-u) * np.array([a, a, b])).sum(axis=1)
21
22
23 def characteristics(values):
24     n = len(values)
25     mean = float(np.mean(values))
26     variance = float(np.var(values, ddof=1))
27     std = math.sqrt(variance)
28     halfwidths = [NormalDist().inv_cdf((1 + p) / 2) * std / math.sqrt(n)
29                  for p in PROBABILITIES]
30     return mean, variance, std, std / mean, *halfwidths
31
32
33 def lag_correlation(values, lag):
34     return float(np.corrcoef(values[:-lag], values[lag:])[0, 1])
35
36
37 def main():
38     original = np.loadtxt(DATA, delimiter=',', skiprows=1)[: , 1]
39     assert len(original) == 300
40     mean, variance = characteristics(original)[:2]
41     a, b = parameters(mean, variance)

```

```

42 generated = generate(a, b, len(original), seed=263)
43
44 table_original = [characteristics(original[:n]) for n in SIZES]
45 table_generated = [characteristics(generated[:n]) for n in SIZES]
46 acf_original = [lag_correlation(original, k) for k in range(1, 11)]
47 acf_generated = [lag_correlation(generated, k) for k in range(1, 11)]
48 boundaries = np.linspace(0, max(original.max(), generated.max()), 11)
49 frequencies_original, _ = np.histogram(original, bins=boundaries)
50 frequencies_generated, _ = np.histogram(generated, bins=boundaries)
51 correlation = float(np.corrcoef(original, generated)[0, 1])
52
53 print(f'a = {a:.6f}; b = {b:.6f}')
54 print('Первые 5 сгенерированных значений:',
55       np.round(generated[:5], 3))
56 for name, row in (('Исходная', table_original[-1]),
57                  ('Сгенерированная', table_generated[-1])):
58     print(f'{name}: m={row[0]:.3f}; D={row[1]:.3f}; '
59           f's={row[2]:.3f}; v={row[3]:.4f}; '
60           f'eps=({row[4]:.3f}, {row[5]:.3f}, {row[6]:.3f})')
61 print(f'r_x(1)={acf_original[0]:.4f}; '
62       f'r_y(1)={acf_generated[0]:.4f}; r_xy={correlation:.4f}')
63 print('Частоты:', frequencies_original.sum(),
64       frequencies_generated.sum())
65
66
67 if __name__ == '__main__':
68     main()

```

Контрольный запуск дал $a = 66.933397$, $b = 142.611408$. Первые пять сгенерированных значений: 47.212, 110.139, 412.266, 84.040, 495.475. Для полной выборки программа получила $\bar{y} = 262.501$, $s_y^2 = 25732.224$, $s_y = 160.413$, $v_y = 0.6111$ и полуширины 15.234, 18.152, 23.856 при вероятностях 0.90, 0.95, 0.99. Обе гистограммы содержат по 300 наблюдений. Результаты совпадают с формой 2 после округления; при демонстрации можно изменить начальное состояние генератора и убедиться, что значения меняются, сохраняя закон распределения.

Таблица 3: Форма 2. Характеристики гипозэкспоненциальной последовательности

Показатель	10	20	50	100	200	300
$\bar{x}$	248.3056	289.2477	276.1503	269.4767	269.7020	262.5007
Δ , %	-9.38	-5.46	0.09	-2.70	1.74	-5.06
s^2	34556.9062	35083.7747	33677.3883	29839.0038	25892.0977	25732.2238
Δ , %	-4.55	-15.66	33.28	14.95	4.10	-12.17
s	185.8949	187.3066	183.5140	172.7397	160.9102	160.4127
Δ , %	-2.30	-8.16	15.45	7.22	2.03	-6.28
v	0.7487	0.6476	0.6645	0.6410	0.5966	0.6111
Δ , %	7.81	-2.86	15.34	10.19	0.28	-1.29
$\varepsilon_{0.90}$	± 96.6929	± 68.8915	± 42.6886	± 28.4132	± 18.7153	± 15.2337
Δ , %	-2.30	-8.16	15.45	7.22	2.03	-6.28
$\varepsilon_{0.95}$	± 115.2167	± 82.0892	± 50.8666	± 33.8564	± 22.3006	± 18.1521
Δ , %	-2.30	-8.16	15.45	7.22	2.03	-6.28
$\varepsilon_{0.99}$	± 151.4204	± 107.8836	± 66.8500	± 44.4948	± 29.3080	± 23.8559
Δ , %	-2.30	-8.16	15.45	7.22	2.03	-6.28

При $n = 300$ среднее новой выборки равно 262.500701 (отклонение -5.0556%), дисперсия 25732.223755 (-12.1712%), стандартное отклонение 160.412667 (-6.2830%), коэффициент вариации 0.611094 (-1.2928%). Совпадение теоретических моментов не означает их точного совпадения в конечной случайной реализации. Среднее генератора находится внутри исходного

приближённого 95%-интервала; это описательное сравнение, а не самостоятельный критерий равенства распределений.

8. Сопоставление последовательностей и распределений




Рис. 5: Сравнение значений исходной и сгенерированной последовательностей

Сопоставимые масштабы и отдельные большие значения воспроизводятся. Совпадение значений при одинаковом номере наблюдения не ожидается: генератор моделирует закон распределения, а не повторяет исходную траекторию.




Рис. 6: График 3. Теоретическая плотность и нормированные гистограммы обеих выборок

Высота столбца нормированной гистограммы равна $n_j/(Nh)$, поэтому её площадь равна единице и она сопоставима с плотностью. Модель воспроизводит основную массу наблюдений и правую асимметрию. Расхождения в отдельных интервалах ожидаемы при 300 наблюдениях; крайние интервалы содержат мало значений, поэтому качество описания хвоста оценивается менее уверенно.

Таблица 4: Частоты на общих интервалах и ожидаемые частоты модели

Левая граница	Правая граница	n_x	n_y	$300p_j$
0.00	117.53	48	49	45.41
117.53	235.05	102	102	100.27
235.05	352.58	65	75	75.56
352.58	470.10	47	38	41.66
470.10	587.63	23	21	20.27
587.63	705.15	8	9	9.33
705.15	822.68	4	6	4.18
822.68	940.21	2	0	1.85
940.21	1057.73	0	0	0.82
1057.73	1175.26	1	0	0.36

Теоретическая вероятность интервала вычисляется как $p_j = F(b_j) - F(a_j)$. Модель не обрезана на максимуме выборки: за последней границей остаётся положительная теоретическая вероятность, поэтому сумма ожидаемых частот в таблице несколько меньше 300.

Максимальное расстояние $D = \sup_t |F_{300}(t) - F_Y(t)| = 0.042858$ характеризует различие эмпирической и подобранной функций распределения. Оно приведено как описательная мера. Обычное p -значение критерия Колмогорова для полностью заданного распределения здесь неприменимо, поскольку параметры оценены по той же выборке. Расстояние между двумя эмпирическими функциями распределения равно 0.073333.

8.1. Корреляция между исходной и новой последовательностями

Коэффициент Пирсона для пар (x_i, y_i) равен

$$r_{xy} = \frac{\sum_{i=1}^{300} (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} = 0.074452.$$

Это слабая линейная связь. Приближённое двустороннее p -значение стандартного теста Пирсона равно 0.1985: значимой линейной связи на уровне 0.05 не обнаружено. Параметры генератора оценены по исходным данным, поэтому полную статистическую независимость результатов всего процесса подбора утверждать нельзя. Однако при зафиксированных параметрах новые случайные числа формируются отдельно от исходных значений.

9. Заключение

Для исходной выборки объёмом 300 наблюдений получены $\bar{x} = 276.4782$, $s^2 = 29298.1731$ и $v = 0.6191$. Интервал для среднего расширяется с ростом доверительной вероятности. Монотонности и устойчивой периодичности не выявлено; автокорреляция на первых десяти сдвигах не противоречит модели некоррелированных наблюдений. По двум моментам выбран трёхстадийный гипоекспоненциальный закон. Генератор воспроизводит положительную асимметрию и масштаб разброса: отклонения среднего и дисперсии новой выборки составили -5.06% и -12.17% . Точность описания редкого правого хвоста по 300 наблюдениям ограничена.